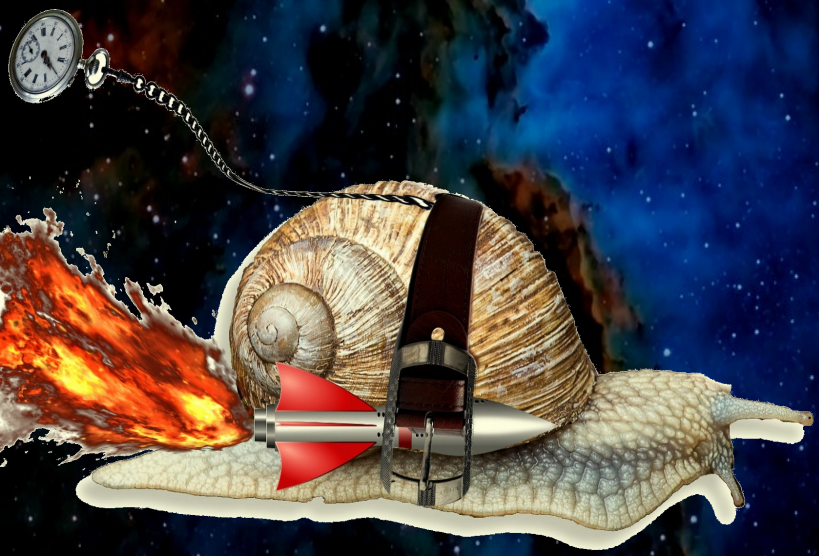
BIOESTATÍSTICA
NA PRÁTICA

Comparando médias

Vol 1



Dr. Heury Ferr

PRÉFACIO

Esta série de livros visa propiciar ao leitor uma experiência agradável de aprendizado de conceitos e aplicações referentes a testes estatísticos de hipótese.

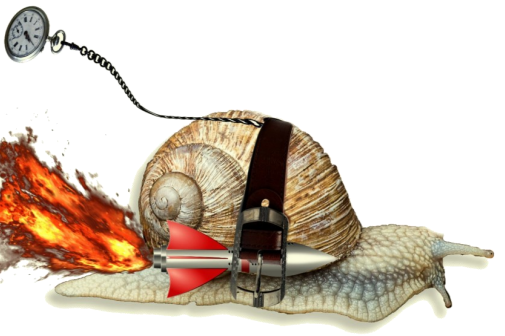
O presente volume trata de introduzir os conceitos mais fundamentais para testes estatísticos de hipótese e comparação de médias. Os capítulos de 1 a 4 formam a base teórica e conceitual para o entendimento e aplicação de testes estatísticos de hipótese. Os capítulos seguintes demonstram a aplicação dos mesmos, através do uso de ferramentas computacionais.

Procuramos um caminho de uma abordagem mais voltada a simplicidade na tentativa de fornecer uma boa compreensão de conceitos teóricos e abordagens práticas.

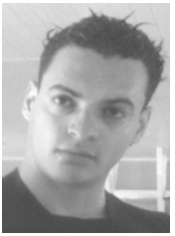
Se essa série conseguir ajudar o leitor a compreender conceitos e aplicações que outrora lhe eram de algum modo obscuros, ela terá cumprido sua missão,

Uma ótima leitura,

Dr. Heury Ferr



SOBRE O AUTOR



Heury Ferr é Doutor em Ecologia quantitativa e evolução. Trabalha com bioestatística aplicada e modelagem matemática em teoria do caos em ecologia e evolução. Atua há muitos anos tanto como consultor em análise bioestatística de dados para artigos científicos e teses de doutorado, quanto ministrando cursos de curta e longa duração de análises uni e multivariadas, para profissionais de empresas de engenharia e consultoria ambiental, e para estudantes e professores a nível de pós-graduação de instituições como USP, Unesp, PUC, Unb, UFG, UFMA, ICMBio, dentre outras, para áreas como Ciências Biológicas, Medicina, Enfermagem, Odontologia, Educação Física, Veterinária, Zootecnica, Química, Matemática e Engenharia Ambiental. É palestrante e conferencista, e também editor da Revista Yalo Ciência.



S U M Á R I O

CAPÍTULO 1 - até página 16

TESTES ESTATÍSTICOS E HIPÓTESES

No que consistem e porque são indispensáveis para que não sejamos enganados na hora de tirar conclusões a partir de nossos dados.

CAPÍTULO 2 - até página 25

O P ESTATÍSTICO

O que realmente é, e como interpretar o elemento comum a todos os testes estatísticos de hipótese dentro da estatística frequentista.

CAPÍTULO 3 - até página 38

ELEMENTOS QUE COMPÕEM UM TESTE ESTATÍSTICO

Os 3 componentes comuns a quaisquer testes estatísticos: O valor de P, a estatística do teste, e os graus de liberdade

CAPÍTULO 4 - até página 44

PODER DOS TESTES E ERROS DE INFERÊNCIA

O poder de um teste estatístico e os erros de inferência tipo I e tipo II.

CAPÍTULO 5 - até página 57

TEST T PARA AMOSTRAS INDEPENDENTES

Executando o teste t para amostras independentes em softwares estatísticos e interpretando adequadamente os resultados.

CAPÍTULO 6 - até página 66

TESTANDO OS PRESSUPOSTOS

Como testar os pressupostos de normalidade e homogeneidade de variâncias e que transformações usar quando os mesmos não são atendidos.



S U M Á R I O

CAPÍTULO 7 - até página 81

TRANSFORMANDO DADOS PARA ATENDER PRESSUPOSTOS E O TESTE T PARA VARIÂNCIAS HETEROGÊNEAS

As duas principais formas de transformação de dados, como aplicá-las, e como aplicar o teste t para variâncias distintas entre os grupos

CAPÍTULO 8 - até página 89

TESTE T PARA AMOSTRAS PAREADAS

Como executar e interpretar o teste t para amostras pareadas

.

CAPÍTULO 9 - até página 98

EQUIVALENTES NÃO PARAMÉTRICOS

Ranks, Teste U de Mann Whitney e Teste de Wilcoxon

C A P Í T U L O 1

TESTES ESTATÍSTICOS E HIPÓTESES

No que consistem e porque são indispensáveis para que não sejamos enganados na hora de tirar conclusões a partir de nossos dados.





Testes estatísticos de hipótese dentro do que podemos chamar de estatística clássica, ou estatística frequentista, são ferramentas matemáticas que permitem a um pesquisador averiguar qual a probabilidade de que o efeito que está observando em seus dados seja fruto do acaso. Quando falarmos de acaso estaremos sempre nos referindo a variações randômicas, de causas erráticas que não podem ser determinadas ou eliminadas por natureza, mas que afetam a variável ou o sistema em estudo, podendo gerar diversos efeitos, incluindo efeitos similares aos efeitos que possuem causas bem definidas. Esses efeitos podem se manifestar na forma de correlações ou diferenças. Quando falamos em correlações queremos dizer basicamente: o que acontece com uma variável quando a outra variável muda de valor, e quando falamos de diferenças, estamos falando de comparações, na maior parte das vezes em comparações de médias ou comparações de frequências de ocorrência.

No caso específico deste volume, abordaremos o aspecto de diferenças entre médias, mais especificamente diferenças entre duas médias. Vamos a um exemplo bem simples. Você está propondo um meio de cultura para cultivar fungos comestíveis, e esse seu meio de cultura utiliza componentes muito mais baratos que os meios de cultura industrializados usados por cultivadores de fungos comestíveis. Seu meio de cultura foi todo construído com base em teoria bioquímica e metabólica que aponta as necessidades nutricionais dos fungos que pretende cultivar. Um primeiro experimento simples que você pode fazer é cultivar fungos de uma dada espécie em um meio de cultura pobre em nutrientes, e cultivar fungos desta mesma espécie no meio de cultura por você proposto (enriquecido em nutrientes). Esperamos que, devido ao fato de seu meio de cultura atender melhor as necessidades nutricionais dos fungos, eles cresçam mais no seu meio de cultura em comparação com o meio pobre em nutrientes. Sendo mais específico, podemos mensurar a biomassa dos fungos cultivados, e no final nossa hipótese (predição baseada em teoria) é: a biomassa de fungos é maior no meio de cultura rico em nutrientes, por este apresentar composição e estrutura favorável a nutrição dos fungos em comparação com o meio de cultura pobre em nutrientes.

Até aqui tudo ótimo. Digamos então que você fez o experimento e encontrou diferenças entre as biomassas médias dos dois meios, e agora? A função dos testes estatísticos é justamente fornecer a você pesquisador, uma estimativa da chance dessa diferença que você pode encontrar em seus dados ser fruto do acaso, e não um efeito real. Dito de outra forma: qual a chance dessa diferenças nas biomassas dos dois meios de cultura ser artefato do acaso, e não devido às diferenças na composição e concentração de nutrientes? É aqui que entra o papel fundamental do teste estatístico de hipótese.



Você está cultivando uma dada espécie de fungo comestível em dois meios de cultura distintos, um pobre em nutrientes e outro enriquecido por você com nutrientes. Você terá várias placas para cada tipo de meio, e espera obter uma biomassa média maior no meio enriquecido, já que os nutrientes favorecem o metabolismo de crescimento do fungo.

Digamos que, após fazer o experimento, você percebe essa diferença apenas olhando para as médias calculadas a partir dos seus dados. E AGORA? Essa diferença é real ou fruto do acaso? SEMPRE se pergunte isso. E quem vai lhe auxiliar a responder qual a chance dessa diferença ser fruto do acaso é um teste estatístico apropriado.



Uma placa do meio de cultura pobre em nutrientes, meio no qual espera-se menor crescimento dos fungos.



Uma placa do meio de cultura rico em nutrientes, no qual espera-se maior crescimento dos fungos.



Assim como numa combinação num jogo de azar, o acaso pode gerar justamente o resultado que você está esperando, por isso sempre se pergunte: qual a chance disso ser fruto do acaso? Nunca se apresse a tirar conclusões apenas olhando para os dados brutos, pois o acaso pode lhe trair, e fazer seus dados mentirem, apontando a você um efeito que na realidade, não existe.

Mas, qual o risco de se tirar conclusões comparativas sem testes estatísticos?

O risco é de você acreditar que correlações ou diferenças existem, quando elas não existem. No nosso caso específico, você corre o risco de acreditar que a diferença entre os rendimentos de biomassa dos fungos existe na realidade, quando na verdade não existe, e a diferença que viu em seus dados não passa de artefato do acaso. Digamos que seu meio de cultura deu uma biomassa média de 8,4g, e o meio de cultura pobre em nutrientes rendeu uma biomassa média de 6,5g. Aí um pesquisador apressado pensa: "viu só, meu meio de cultura de fato provoca melhor crescimento", talvez sim, mas precisamos antes descartar o acaso como explicação para essa diferença entre as médias. Por que? Para se proteger de passar um vexame em dizer ao mundo que seu meio de cultura promove maior biomassa dos fungos, quando na verdade ele não promove. Se não tiver feito um teste estatístico e tiver a infelicidade de que seu meio de cultura não funcione, você descobrirá isso de uma forma bem dolorosa: outras pessoas vão replicar seu experimento, e se o seu resultado foi simplesmente artefato do acaso, os experimentos deles mostrarão resultados opostos ao seu. E aí, já era, você estava errado. Claro, o ideal seria fazer e repetir seu experimento algumas dezenas de vezes para observar se sempre ocorre o mesmo padrão, mas é justamente para poupar você disso que existem as ferramentas estatísticas de teste de hipótese. A partir de um único experimento, o seu, o teste estatístico de hipótese tenta lhe fornecer uma estimativa para a chance de que aquilo que você obteve tenha sido artefato do acaso. Se essa chance é alta (geralmente define-se alta como maior que 5%), você não vai discutir as diferenças, vai aceitar o acaso como explicação (hipótese nula). Se essa chance é baixa (geralmente define-se baixa como menor que 5%), você aí sim vai descartar o acaso como explicação (descartar a hipótese nula).



Hipótese Nula e Hipótese Alternativa

Há muitas formas filosóficas de se definir ciência e portanto, hipótese científica. Porém, quando se trata de testes estatísticos dentro da estatística frequentista, há uma definição operacional muito clara: **hipótese é uma predição baseada em teoria**. É uma previsão do que vai acontecer em seu experimento, e de preferência seguida de um motivo teórico para aquilo. Temos nos testes estatísticos tradicionais duas hipóteses sempre concorrentes:

Hipótese Nula – H_0 (Não há efeitos, correlações ou diferenças, qualquer efeito, correlação ou diferença que se observe é simplesmente fruto do acaso).

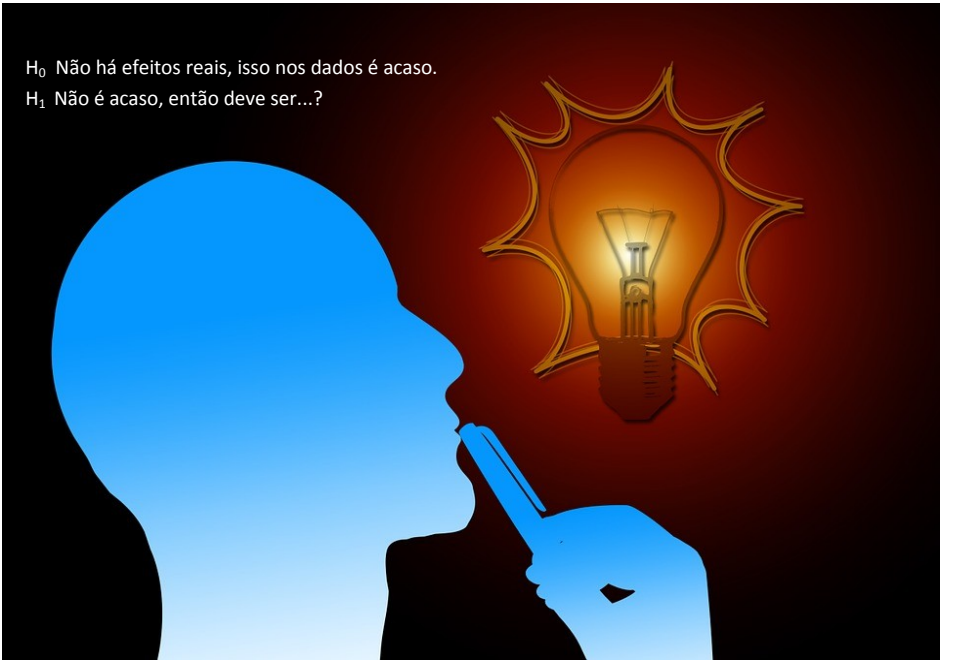
Hipótese Alternativa – H_1: Há efeitos, correlações ou diferenças, por motivos A, B, C, etc...

No nosso caso específico, da comparação das biomassas dos fungos, temos o seguinte:

Hipótese Nula – H_0 (Não há diferenças entre as médias de biomassas, qualquer diferença observada é simplesmente artefato do acaso).

Hipótese Alternativa – H_1 (Há diferenças entre as médias porque há uma diferença clara na composição e quantidade de nutrientes entre os meios, isso afeta o metabolismo de crescimento dos fungos, e isso será refletido na variável biomassa).

A parte sublinhada acima é o motivo teórico para se esperar a diferença. É a justificativa para a ocorrência dos efeitos. É a presença desse motivo teórico que difere uma hipótese científica de uma hipótese estatística.



Ter em mente de forma clara a importância de hipóteses bem formuladas, é o primeiro passo para se dominar bem técnicas de análise estatística de dados.

Há casos em que a formulação de hipóteses alternativas com base em teoria não é possível pela total ausência de conhecimento prévio sobre o sistema, nestes casos procede-se a uma abordagem mais exploratória e a formulação de hipóteses puramente estatísticas é perfeitamente aceitável.

De um ponto de vista puramente estatístico a formulação das hipóteses se dá simplesmente assim:

Hipótese Nula - H_0: Não há efeitos, o que se observou é artefato do acaso.

Hipótese Alternativa - H_1: Há efeitos.

Em termos de notação é comum o uso do símbolo μ_1 para representar uma das médias, digamos a do meio pobre em nutrientes, e μ_2 para se representar a média do meio enriquecido. Com essa simbologia se escreve a formulação das duas hipótese acima do seguinte modo:

H_0: $\mu_1 = \mu_2$

H_1: $\mu_1 \neq \mu_2$

Observe que uma hipótese alternativa puramente estatística não necessita de justificativa para a ocorrência dos efeitos. Parece algo sutil, mas é profundo. Essa abordagem é explorativa, interessante quando não se sabe nada sobre o sistema que se está estudando. Estatisticamente não há nada de errado. Mas para você como cientista, o perigo dessa abordagem é que você pode encontrar efeitos, correlações, ou diferenças, que não sabe como explicar, e mesmo que ache uma explicação depois, simplesmente encontrá-la não explica ainda os resultados, esse é um ponto importante de destacarmos aqui. Vamos mais a fundo. Se você encontra um efeito, não sabe explicar ele, mas depois encontra alguma justificativa teórica para tal efeito, aquela justificativa só é realmente válida se você conduzir outro experimento para testá-la. Por exemplo: Eu comparei biomassa de fungo usando várias amostras coletadas em campo de dois tipos de solo . Vi que a média de biomassa de fungos foi maior para o tipo de solo A do que para o tipo de solo B, e que isso não se deve ao acaso (já fiz o teste estatístico

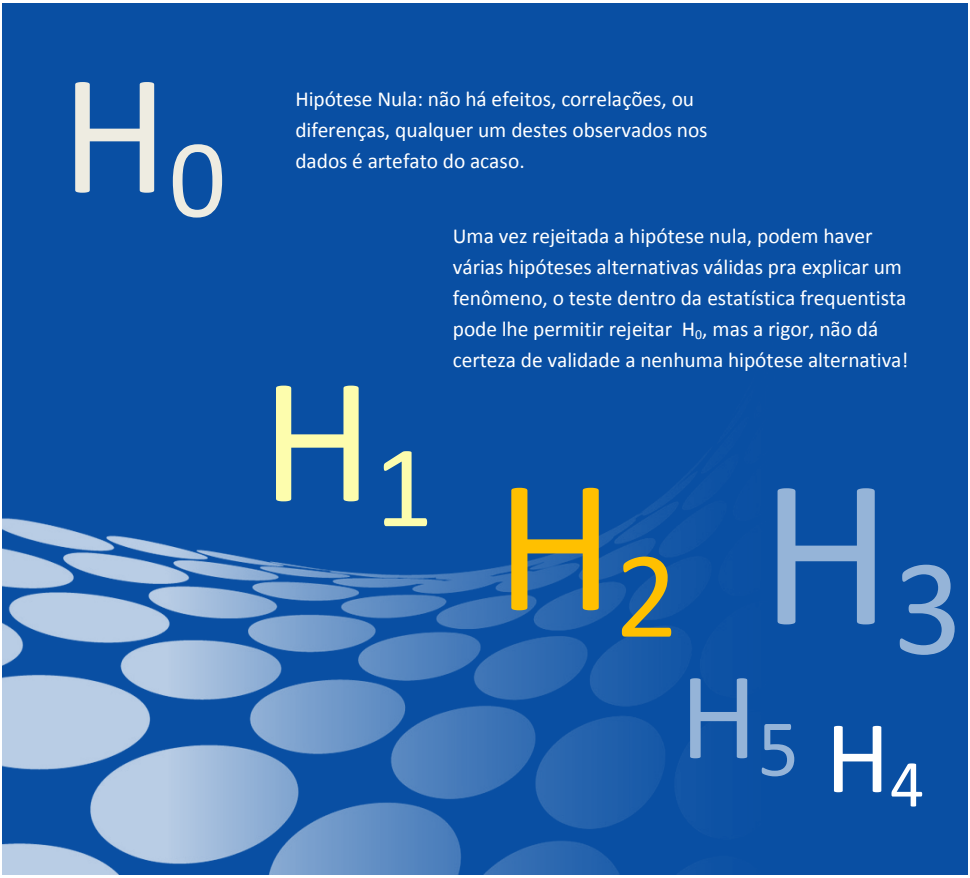


Quando procura razões lógicas a posteriori para explicar um padrão visto nos dados, a má notícia é que na maior parte das vezes você vai encontrar tal explicação, mas o fato de a ter encontrado e o fato de ela ser lógica, não significa que explique o fenômeno, é necessário conduzir outro experimento para testar isso!

que me permitiu descartar a hipótese nula, isto é, o acaso como explicação). Mas não sei explicar porque há essa diferença de biomassas entre os dois tipos de solo, apenas a encontrei, e o teste estatístico me mostra que ela não é simplesmente artefato do acaso, então, provavelmente tem algo ali.

Olhando outras variáveis acabei descobrindo que existem mais sais e nitrogênio no solo onde os fungos tiveram maior crescimento, logo eu penso: provavelmente a biomassa foi maior aqui porque este tipo de solo é mais rico em nutrientes. Ótimo. MAS, você precisa agora conduzir um outro estudo onde vai isolar uma ou mais das variáveis que representam nutrientes, e aí sim fazer a comparação. Por que? Porque uma explicação lógica encontrada *a posteriori* não implica ser uma explicação correta simplesmente por ser lógica. O que mais encontramos em ciência são predições que fazem todo o sentido lógico, mas que são completamente contraditas por experimentos.

Além disso, podem haver ainda muitos outros fatores que podem afetar seu sistema, e cada um destes fatores poderia indicar uma hipótese lógica que explicaria igualmente bem o fenômeno. Por exemplo, poderia simplesmente haver uma espécie de fungo competidora crescendo no extrato do tipo de solo no qual você obteve a menor biomassa para o fungo. Então, a espécie cresceu menos ali,



não porque o solo era pobre em nutrientes, mas porque outra espécie estava competindo com ela por nutrientes! Logo, isso também é uma explicação perfeitamente lógica! E só pode ser confirmada se você conduzir outro experimento onde controla a presença do competidor. E claro, pode até conduzir um experimento mais elaborado onde controla tanto a presença do competidor quanto a quantidade de nutrientes. Mas o ponto importante a ser notado aqui é: DIFERENÇAS OBSERVADAS PODEM TER INÚMERAS CAUSAS, o fato de eu simplesmente achar uma explicação que parece lógica para aquela diferença, não significa necessariamente que eu encontrei a explicação correta! Somente um experimento feito especificamente para testar aquela explicação pode nos dizer se ela é de fato a causa.



Podem haver muitas hipóteses para se explicar um dado fenômeno, há outras vertentes e escolas na estatística, como a estatística bayesiana, que permitem inferir probabilidades para dar pesos a diferentes hipóteses alternativas.

Os testes permitem rejeitar a hipótese nula, eles nada dizem sobre a hipótese alternativa

Temos o confronto entre duas hipóteses: uma hipótese nula (acaso), e outra hipótese alternativa que acreditamos explicar o fenômeno. Digamos que a hipótese nula tenha sido rejeitada após você conduzir a análise estatística, isto é, o acaso não é (provavelmente) a explicação para aquela diferença entre as médias. Muitos pesquisadores, e quando digo muitos, são muitos mesmo, concluem daí intuitivamente que há portanto elevada chance de A HIPÓTESE ALTERNATIVA ESTAR CORRETA, pois pensam: só tenho duas hipóteses concorrentes, a nula e a alternativa, se a chance de encontrar esse resultado assumindo que a hipótese nula é verdadeira é de apenas 1%, a chance da hipótese alternativa ser verdadeira é de 99%! *Parece lógico, mas esse raciocínio não está certo*, pois o P estatístico nem se quer sabe qual é sua hipótese alternativa, ele nada pode dizer sobre ela. Há dois excelentes artigos na Revista Nature, um de Fevereiro de 2014, de Regina Nuzzo, e outro de Monya Baker, 2016 (ver referências no final do livro), que discutem e esclarecem bem esse ponto, exatamente como estamos abordando aqui, e a necessidade de artigos assim em 2014, e em pleno ano de 2016, mostra claramente como professores de bioestatística e muitos pesquisadores ativos fazem ainda muita confusão com o que um teste estatístico clássico realmente significa.

Há outras vertentes da estatística, como a estatística Bayesiana por exemplo, que permitem atribuir diferentes pesos de validade para diferentes hipóteses alternativas. Tratam-se de linhas conceitualmente e filosoficamente bem distintas da estatística clássica ou frequentista, mas muito interessantes de serem estudadas. Antes de discutir validade de hipóteses alternativas, um primeiro passo coerente é poder descartar o acaso como explicação provável para o fenômeno de estudo.



- Senhor pescador, o senhor viu passar por aqui meu cachorro há uns 20 minutos? É um pitbull com coleira do corinthians.

- Há 20 minutos teve um latido e passos correndo naquela direção, pelo barulho que fez no mato era um animal forte, se era o seu cachorro, eu não sei, isso é problema seu, não cabe a mim responder isso.

De modo similar um teste estatístico dentro da estatística frequentista, nunca pode dar validade a uma hipótese alternativa, só pode dizer: "não é acaso amigo, se é a sua hipótese, não sei".

As implicações disto são bem interessantes. Digamos que para o exemplo citado dos fungos tenhamos as seguintes hipóteses para explanar o maior crescimento para o meio enriquecido em nutrientes, em comparação com o meio pobre em nutrientes:

Hipótese Nula (H_0): Não há diferença nos crescimentos, qualquer diferença observada é simplesmente fruto do acaso.

Hipótese Alternativa 1 (H_1): A maior riqueza de nutrientes propicia uma melhor nutrição, o que favorece o metabolismo de crescimento, assim o meio enriquecido terá biomassa maior.

Hipótese Alternativa 2 (H_2): Por um incidente na logística do experimento, os recipientes que continham menos nutrientes, também eram feitos de um material que ressecava excessivamente, reduzindo assim a umidade do micro-ambiente, indispensável ao crescimento dos fungos, fazendo com que neste meio a biomassa fosse menor.

Quando um teste estatístico diz a você que a chance de aquela diferença entre as médias ser fruto do acaso é baixa, menor que 5%, ele quer dizer que você pode rejeitar a hipótese nula, mas não quer dizer qual hipótese alternativa pode ser a verdadeira, e mesmo que você só tenha uma única hipótese alternativa, a rigor ele não diz nada sobre ela. Então, essa é uma limitação clara que os pesquisadores precisam ter em mente, uma limitação inerente as ferramentas que utilizam dentro da estatística frequentista. A probabilidade de 1% de aquele efeito acontecer assumindo que a hipótese nula seja verdadeira NÃO SIGNIFICA UMA PROBABILIDADE DE 99% DE SUA HIPÓTESE DE PESQUISA (hipótese alternativa) SER VERDADEIRA.

Quando um teste estatístico diz a você que a chance de aquele efeito encontrado, assumindo que a hipótese nula é verdadeira, é menor que 5%, ele quer dizer que você pode rejeitar a hipótese nula, mas não quer dizer qual hipótese alternativa pode ser a verdadeira, e mesmo que você só tenha uma única hipótese alternativa, a rigor ele não diz nada sobre ela.



CAPÍTULO 2

O P ESTATÍSTICO

O que realmente é, e como interpretar o elemento comum a todos os testes estatísticos de hipótese dentro da estatística frequentista.





Essa probabilidade da qual falamos até agora, de que aquilo que você observou seja fruto do acaso, é o P estatístico, de todos os testes estatísticos dentro da estatística frequentista ou estatística clássica. Para todos os testes, a interpretação é a mesma, o P é uma probabilidade que representa a chance de que aquele efeito seja fruto do acaso. Ou dito de outra modo, fornece a você uma probabilidade para que com base nela possa aceitar ou rejeitar a hipótese nula. Por pura convenção, utiliza-se muito frequentemente o valor de 5%, como sendo um limiar para aceitação ou rejeição da hipótese nula. Se o P é menor que 5% rejeita-se a hipótese nula, do contrário, aceita-se. Esse valor de probabilidade com o qual o P será comparado como referência, para a partir daí se tomar uma decisão de aceitação ou rejeição da hipótese nula, é o nível de significância de um teste estatístico, é chamado de alfa, representado pela respectiva letra grega α. Os valores mais tradicionalmente utilizados para o nível de significância (α), são 5% (universalmente o mais utilizado), 1% (utilizado em alguns casos onde se quer maior rigor) e 10% (menos utilizado).

Posso usar outros valores de alfa? Sim, teoricamente, você pode usar por exemplo um α de 15%, e digamos, fixando esse α *a priori* você poderia encontrar quem sabe um p de 14% (p=0,14) e considerar isso como uma probabilidade baixa de a hipótese nula ser verdadeira, e portanto rejeitá-la. Um primeiro ponto é que você teria de fazer muitíssimos cálculos na mão para conseguir gerar tabelas de probabilidade para um nível de significância α como este que adotou, e por fim provavelmente não iria conseguir publicar seu trabalho em lugar nenhum, pois a comunidade científica mundial, por convenção, não aceita que se rejeite a hipótese nula com valores de probabilidade assim tão elevados. Então, o que existe na prática são os valores de 5%, 1% e 10% para α.

Você pode portanto pensar assim:

P< α: implica numa chance muito pequena do que eu estou vendo ser fruto do acaso, uma chance muito pequena de isso acontecer assumindo que a hipótese nula é verdadeira, logo eu rejeito a hipótese nula, rejeito o acaso como explicação.

P>=α: implica numa chance grande do que eu estou vendo ser fruto do acaso, uma chance grande de isso acontecer assumindo que a hipótese nula é verdadeira, logo eu não posso rejeitar o acaso como explicação, eu não rejeito, portanto, a hipótese nula. O α mais largamente utilizado é 0,05, você pode se habituar agora no início a pensar assim:

P≥0,05 -> ACASO EXPLICA (aceito hipótese nula).

P<0,05 -> REJEITO O ACASO COMO EXPLICAÇÃO (rejeito a hipótese nula).

Quando se rejeita a hipótese nula utiliza-se a expressão: O RESULTADO FOI SIGNIFICATIVO. Isso quer dizer que há uma chance muito baixa de ele ter sido fruto do acaso. É uma expressão que em termos de nomenclatura poderia ser criticada, pois dá a impressão de que aceitar a hipótese nula é algo NÃO SIGNIFICATIVO, como se fosse sem significado para o pesquisador, o que pode não ser verdade, mas problemas de nomenclatura a parte, é uma expressão muito utilizada, sempre que a ouvir, significa que a hipótese nula foi rejeitada.





A maneira tradicional de se ensinar o conceito de um p estatístico é as vezes confusa para muitas pessoas

Se você buscar pela internet, Wikipédia, sites de ensino de estatística, em diversos livros textos, a definição que encontrará de p estatístico será algo assim:

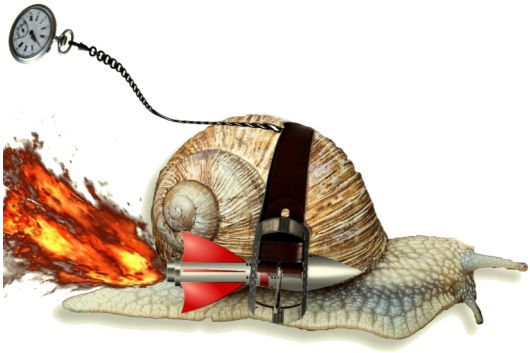
Num teste de hipótese estatístico, o P é a probabilidade de se obter uma estatística de teste igual ou mais extrema que aquela observada em uma amostra, sob a hipótese nula.

Entendeu? Talvez não. Essa é uma definição tecnicamente correta mas didaticamente não muito adequada, e em termos práticos perde um pouco em eficiência no que diz respeito a compreensão. Ela me lembra certa vez uma conversa de rádio que o piloto alemão Michael Schumacher estava tendo com seu engenheiro da Mercedes durante uma corrida, o engenheiro deu uma informação técnica perfeita, mas a apresentou com termos complexos, igual a definição acima, e Schumacher imediatamente respondeu: isso em inglês quer dizer o que? Bom, do mesmo modo você pode fazer como o piloto alemão, olhar a definição acima e dizer: "isso em português quer dizer o que? Eu sou um pesquisador, o que uma definição como essa me diz sobre meu experimento?"Ok, reclamação aceita, vamos tentar melhorar isso.

O p é uma probabilidade que reflete a chance do efeito que você observou ser fruto do acaso. E isso é tudo. Novamente, ele não dá peso a sua hipótese de pesquisa. Há muitos professores de bioestatística e pesquisadores que não entendem esse conceito e isso gera muita confusão, novamente recomendo fortemente que leia os artigos de Regina Nuzzo, na Nature de 2014, e Baker, 2016, também na Nature, sobre o tema (ambos indicados nas referências no final do livro). Na definição mais usual dada anteriormente fala-se em estatística do teste ao invés de efeito. Acontece que o efeito que você observou vai ser representado por uma métrica chamada estatística do teste, e tecnicamente o P é a probabilidade de encontrar um valor de estatística do teste igual ou mais extremo que aquele encontrado nos seus dados por simples acaso (hipótese nula verdadeira). A estatística do teste é um número estimado a partir de várias informações, mas que vai refletir no fim, embora indiretamente, o tamanho do efeito que você está estudando. No fim, o P é a chance de encontrar um efeito igual ou mais extremo a este que está observando por simples acaso (hipótese nula verdadeira), logo: probabilidade de um efeito, correlação, ou diferença, similar ao observado nos seus dados, ser fruto do acaso, e por similar queremos dizer: igual ou mais extremo.



Um P pequeno não quer dizer que há uma chance pequena de você estar errado, e sim, que há uma chance pequena de aquilo ser fruto do acaso, mesmo que pequena, essa chance existe.



Vamos dissecar um pouco mais esse conceito:

FORMA TRADICIONAL: o **P** é a probabilidade de se obter uma estatística de teste igual ou mais extrema que aquela observada em uma amostra assumindo que a hipótese nula seja verdadeira.

COMEÇANDO A TRADUZIR: o P é a chance de encontrar um efeito igual ou superior a este que eu encontrei por simples acaso (hipótese nula verdadeira).

REFINANDO MAIS: o P é a chance de encontrar um resultado similar a este que encontrei assumindo que a hipótese nula seja verdadeira.

***CURTO E DIRETO**:* a chance que algo similar a esse efeito, correlação ou diferença observada nos dados, seja simplesmente devido ao acaso.

Ótimo. Voltando ao nosso experimento com fungos, qual a hipótese nula? Não há qualquer diferença no rendimento de biomassa entre o meio de cultura pobre e o meio de cultura enriquecido em nutrientes. Então, suponhamos que você fez o experimento e encontrou que a média para o meio enriquecido foi 8,4g, e o meio de cultura pobre em nutrientes rendeu uma biomassa média de 6,5g. ISSO A PRIMEIRA VISTA PARECE BOM, SUGERE A VOCÊ QUE SEU MEIO CUMPRE O OBJETIVO DELE, mas, digamos que ELE NA VERDADE NÃO PROMOVA MAIOR GANHO DE BIOMASSA DOS FUNGOS, OU SEJA: A HIPÓTESE NULA É VERDADEIRA, NÃO HÁ DIFERENÇAS DE RENDIMENTO, ENTÃO, QUAL A CHANCE DE EU ENCONTRAR AO ACASO UMA DIFERENÇA IGUAL OU MAIOR A ESSA DIFERENÇA QUE ENCONTREI MESMO QUE NA REALIDADE OS MEIOS NÃO SEJAM DIFERENTES?

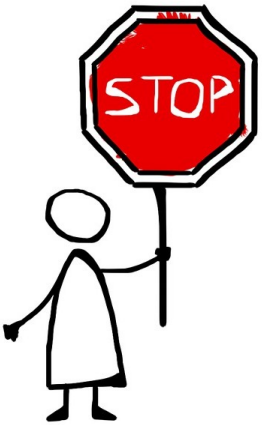
É isso que um P estatístico denota! E o teste estatístico representa essa diferença observada não simplesmente subtraindo uma média da outra, mas através de um número chamado estatística do teste, que é formalmente mais elaborado, que leva em conta não só as diferenças entre as médias, mas outros elementos também, como os desvios padrões para os dois grupos, e o tamanho amostral dos dois grupos. **Esse número mais elaborado que tenta refletir quantitativamente o efeito que você está mensurando é chamado de estatística do teste**. E mais uma vez, NO FIM O P É simplesmente: a chance desse efeito que vejo nos dados estar lá por simples acaso.

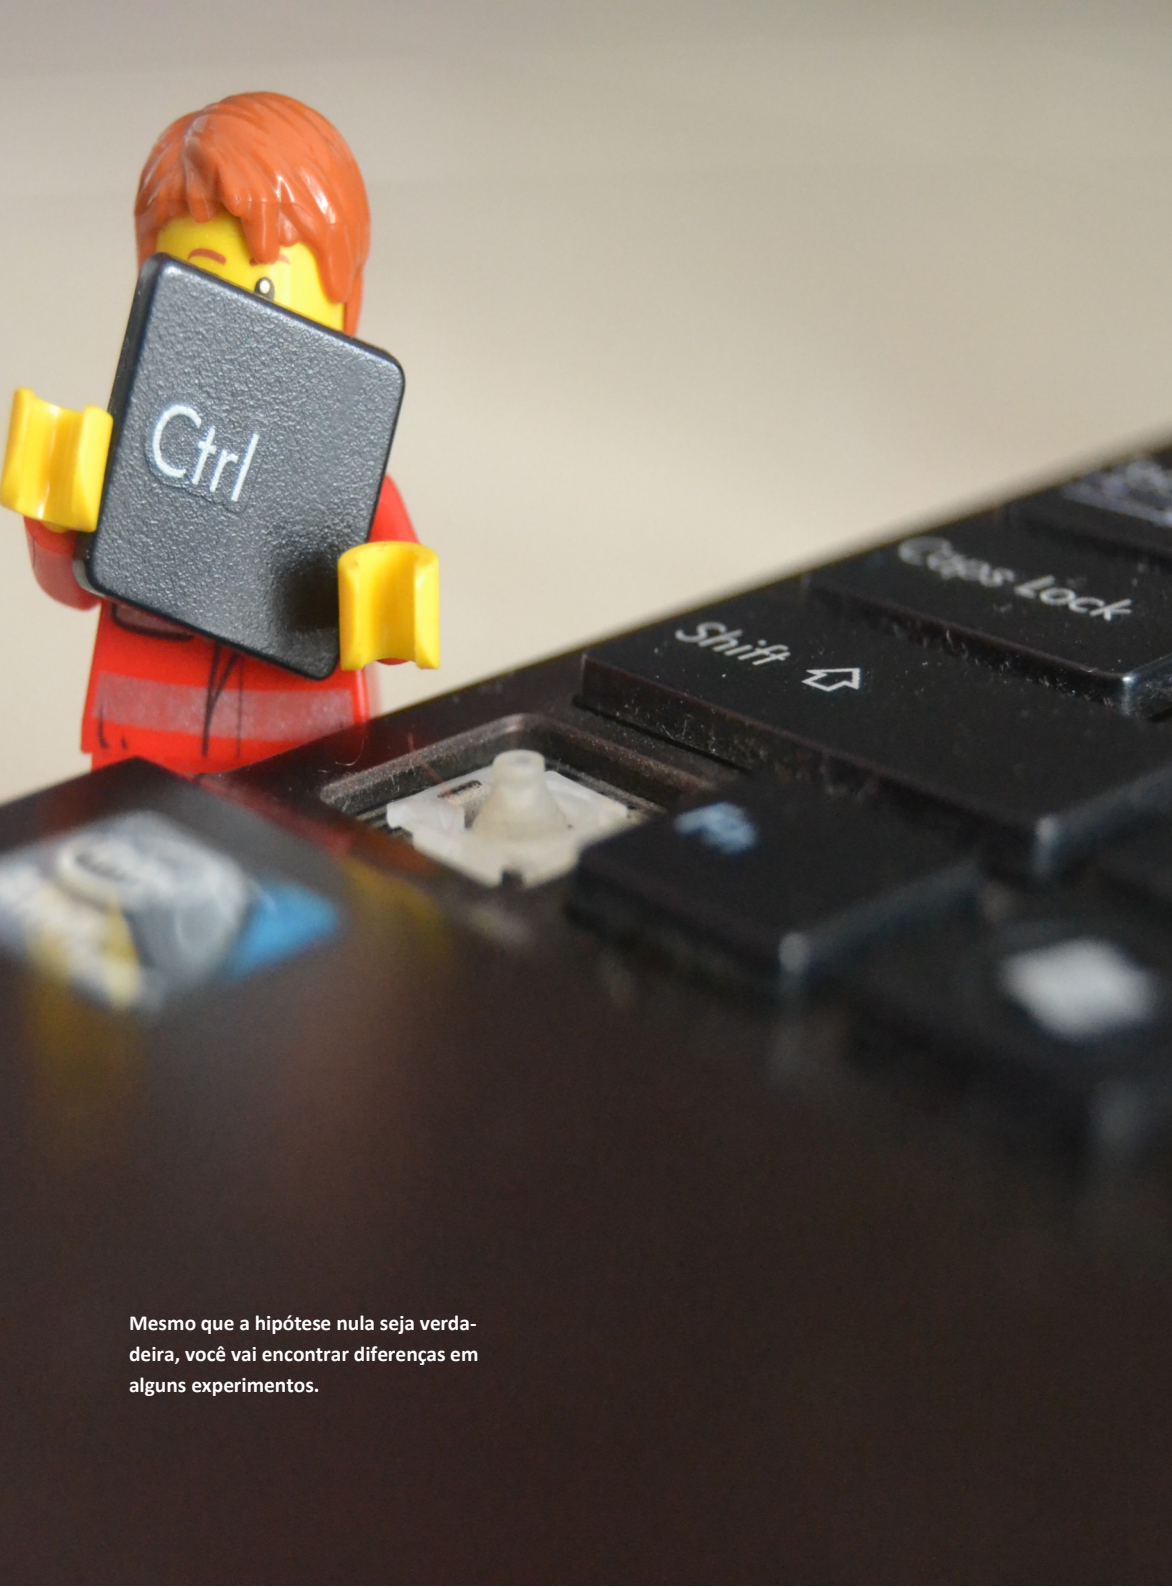
Mesmo que a hipótese nula seja verdadeira, você vai encontrar diferenças em alguns experimentos

Lembre-se, hipótese nula verdadeira quer dizer QUE NA REALIDADE NÃO EXISTE QUALQUER EFEITO, QUALQUER CORRELAÇÃO, QUALQUER DIFERENÇA. Qualquer diferença que foi observada foi fruto do acaso (flutuações randômicas). É bom sempre termos claro em mente que mesmo assim, mesmo que não existam efeitos, SEUS DADOS PODEM MENTIR, MESMO QUE NÃO EXISTA EFEITO ALGUM se você fizer muitos experimentos, alguns experimentos, mostrarão que há efeitos, quando na verdade não há. Então, se você está querendo ver efeitos, e o experimento lhe mostra o efeito, não caia na tentação de já aceitar aquilo, primeiro se pergunte: ok, isso é o que eu esperava, MAS qual a chance disso aqui ter surgido só por acaso? É aí onde entram os testes estatísticos. Se essa chance for pequena, menor que 5%, ótimo, a chance de isso ser ao acaso é baixa, e aí sim poderá rejeitar a hipótese nula.

Posso não rejeitar a hipótese nula e ainda assim discutir minha hipótese alternativa?

Não. Algumas pessoas de fato fazem isso. Encontram um valor de p elevado, logo não podem rejeitar a hipótese nula, isso significa que o simples acaso pode ter produzido aquele efeito que se pensava ser por outro motivo, ainda assim a pessoa continua em frente e diz: não posso descartar o acaso como explicação, mas também não posso descartar a minha hipótese porque pela lógica acontece isso e isso e aquilo... STOP, PLEASE :) Não faça isso jamais! Por que? Porque há um elevado risco de você estar se enganando e enganando a sua plateia ao conduzir uma discussão assim. Queremos em ciência ter as menores chances de erro possíveis ao tirar nossas conclusões, e isso começa descartando o acaso como explicação para o fenômeno. Mesmo descartando o acaso, não poderíamos ter certeza de que nossa hipótese é verdadeira, imagina sem conseguir descartá-lo! A incerteza na discussão acaba sendo muito elevada, então, se não pode rejeitar a hipótese nula você não vai discutir a sua hipótese alternativa. Não vai nunca dizer: bom, o valor de P foi elevado sim, mas aqui pelos dados brutos eu posso ver que a média de crescimento foi maior no meio enriquecido conforme eu previa... Bom, caso se pudesse e fosse seguro tirar conclusões deste modo, não seriam necessários testes estatísticos de hipótese :).





Mesmo que a hipótese nula seja verdadeira, você vai encontrar diferenças em alguns experimentos.



O que o P não é... E como não interpretá-lo!

⇒ *O P não é uma probabilidade a ser usada como evidência de veracidade da hipótese alternativa*. Um P estatístico de 0,01 por exemplo, não significa que porque eu tenho 1% de chance de esse resultado ser gerado por acaso, tenho automaticamente 99% de chance de a hipótese alternativa ser correta, O P NÃO FORNECE TAL INFORMAÇÃO, ele só diz que não é ao acaso, se sua hipótese alternativa é correta ou não, ele não pode dizer.

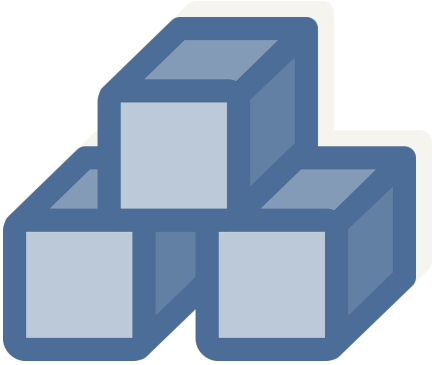
⇒ *Um P estatístico muito pequeno, não é uma certeza de que a hipótese nula seja falsa*. Pode acontecer de um raio cair sobre alguém, por baixa que seja a probabilidade não é mesmo? Do mesmo modo, pode acontecer de você rejeitar a hipótese nula, MAS AINDA ASSIM ELA SER VERDADEIRA, e você cometer um erro! Falaremos mais na frente especificamente sobre os erros de inferência, mas por hora, convêm entender que os testes estatísticos são limitados, e que se um resultado é muito impactante para a literatura, convêm repetir o experimento para não correr a infelicidade de se enganar, mesmo com um valor de P bem pequeno.

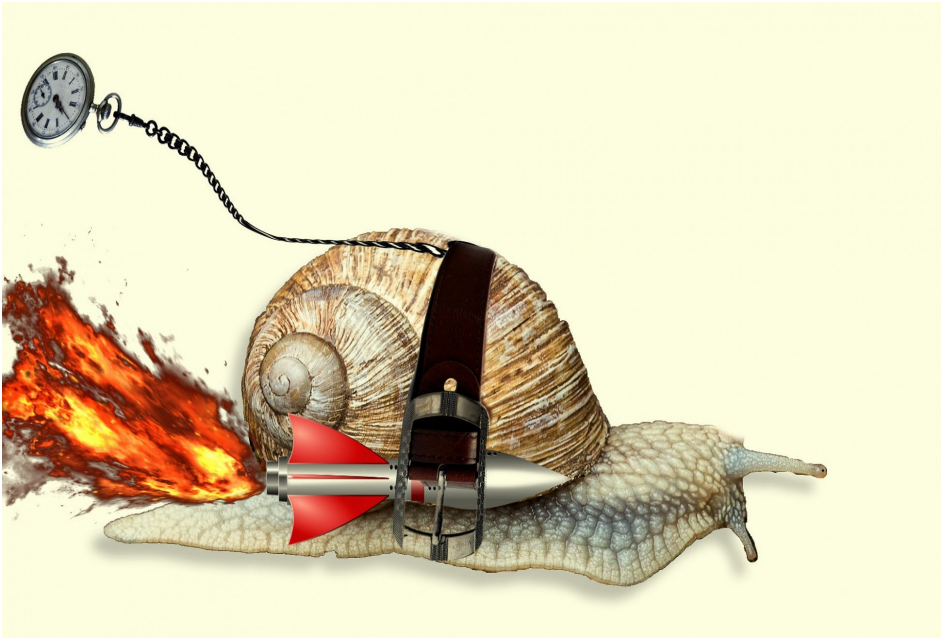
⇒ *O P não é a probabilidade da hipótese nula ser verdadeira*, ELE É A PROBABILIDADE DE ENCONTRAR AQUELA CONFIGURAÇÃO DE DADOS ASSUMINDO QUE A HIPÓTESE NULA É VERDADEIRA. Então, já se assume no início da análise que a hipótese nula é verdadeira! **Nunca pense que a lógica de um teste estatístico** é: DADO QUE ENCONTREI ESSE VALOR DE P, qual a chance de a hipótese nula ser verdadeira? **A LÓGICA é**: dado que achei isso nos dados, qual a chance de eu ter encontrado isso assumindo que a hipótese nula seja verdadeira? Seria em analogia algo assim: assumindo que o namorado da minha amiga é fiel qual a chance de eu encontrar ele num bar beijando duas mulheres como acabei de encontrar? Baixa, então você descarta essa ideia.

C A P Í T U L O 3

ELEMENTOS QUE COMPÕEM UM TESTE ESTATÍSTICO

Os 3 componentes comuns a quaisquer testes estatísticos: O valor de P, a estatística do teste, e os graus de liberdade.





Todos os testes estatísticos dentro da estatística frequentista possuem basicamente três elementos chave:

1) **P estatístico**: probabilidade de encontrar um efeito igual ou mais extremo que aquele por simples acaso.

2) **Estatística do Teste**: número abstrato que intenta retratar numericamente o tamanho do efeito, correlação ou diferença com a qual você está lidando.

3) **Graus de Liberdade**: Peças de informação independentes, são os elementos de sua amostra que fornecem informação para a inferência.

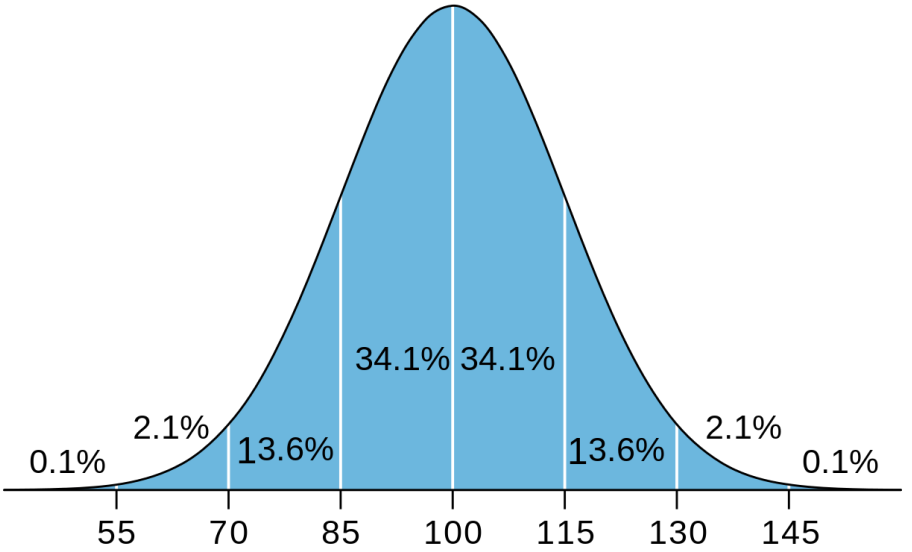
Basicamente, um teste estatístico é um conjunto de procedimentos matemáticos que implicam em encontrar um valor de P, a partir de uma estatística de teste, calculada das suas peças de informação. A meta é lhe fornecer um valor de P para que a partir dele você possa ter respaldo para aceitar ou rejeitar a hipótese nula, e para alcançar tal meta, se faz necessário a presença dos outros dois elementos: estatística do teste e graus de liberdade (peças independentes de informação).



DE ONDE VEM O P ESTATÍSTICO?

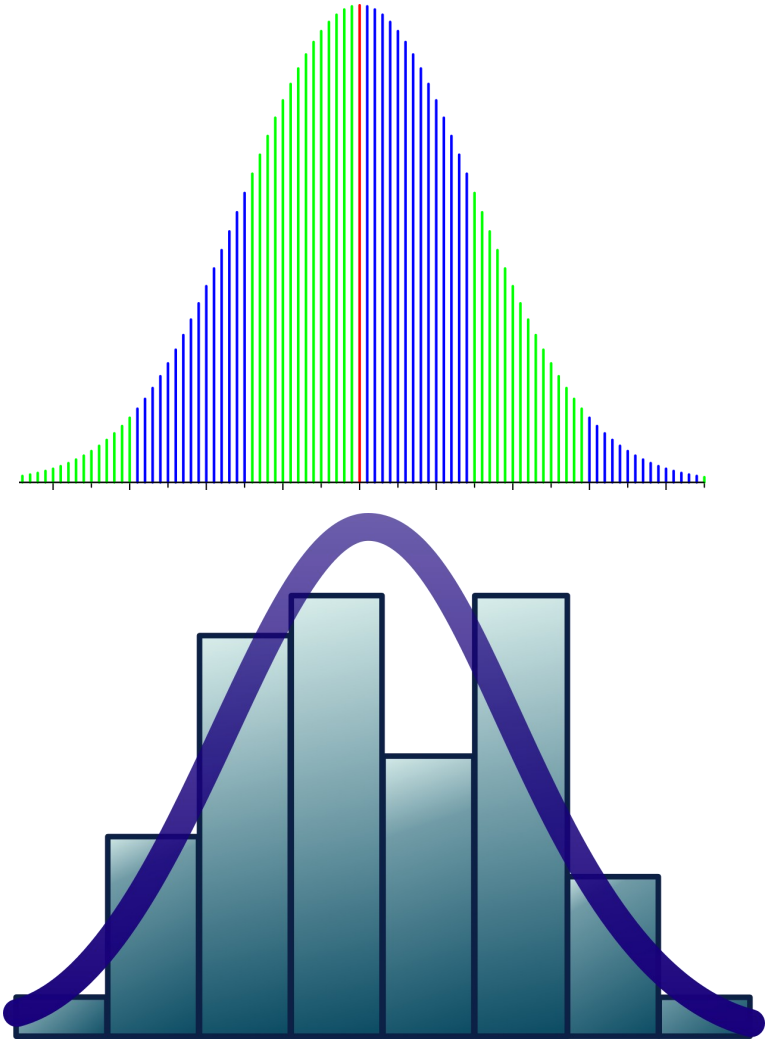
Como se calcula um P estatístico? Essa é uma pergunta realmente interessante. Voltemos ao experimento hipotético em que você está comparando duas médias, a média de biomassa do meio pobre em nutrientes onde se espera menor crescimento dos fungos, logo, menor biomassa, e a média do meio rico em nutrientes, onde se espera maior crescimento dos fungos, logo, maior biomassa. Como uma ferramenta matemática pode lhe dizer que uma diferença entre as médias tem baixa ou alta chance de ocorrer por simples acaso? Ou formulando a mesma pergunta com outras palavras: Como uma ferramenta pode lhe dizer que uma diferença entre médias tem probabilidade alta ou baixa de ocorrer assumindo que a hipótese nula seja verdadeira? ISSO SO É POSSÍVEL ASSSUMINDO-SE QUE SEUS DADOS SE AJUSTAM A UMA DISTRIBUIÇÃO DE PROBABILIDADE PREVIAMENTE DETERMINADA.

Uma distribuição de probabilidade é uma função matemática, que assinala uma probabilidade de ocorrência para valores específicos ou faixas de valores específicos de uma variável. Então, se sua variável segue uma distribuição de probabilidade, para qualquer valor ou faixa de valores que sua variável possa assumir, existe uma probabilidade de ocorrência AO ACASO PARA AQUELES VALORES, e a partir daí, pode-se a partir de muitos procedimentos analíticos se estimar probabilidades de ocorrência para as diferenças entre as médias dos grupos que está estudando para essa variável. Então, se sua variável de estudo é biomassa de fungos, e você encontra uma diferença de 1g de rendimento entre a biomassa para o meio rico em nutrientes em comparação com o meio pobre, qual a chance de isso acontecer se a hipótese nula for verdadeira? Só é possível responder essas perguntas assumindo que a métrica usada para quantificar a diferença entre as médias (estatística do teste) segue alguma distribuição de probabilidade teórica, para a qual já existem tabeladas as probabilidades de ocorrência para valores específicos ou faixas de valores.



Representação gráfica de uma função normal de distribuição de probabilidade. A maioria dos testes estatísticos precisa assumir que seus dados seguem alguma distribuição, e a maior parte deles assume que seus dados seguem a distribuição normal. Quando fala-se que os dados são normalmente distribuídos, ou de teste da normalidade dos dados, estamos sempre nos referindo à verificação de que eles tenham a forma dessa curva representada acima. E se os dados não seguem a distribuição teórica ? Aí claramente sua inferência estará com erros se a técnica utilizada tiver isso como pressuposto básico.

A curva acima é a representação gráfica de uma função de distribuição de probabilidade. Essa é a chamada distribuição normal, que possui a característica visual de ser uma curva simétrica em forma de sino, há algumas propriedades matemáticas que fazem com que essa curva seja assim, ela possui por exemplo as medidas de tendência central, média, moda e mediana, iguais, mas não vamos nos ater a estes pormenores neste momento. O importante nesta fase é você entender como se interpreta uma curva de distribuição de probabilidade. O eixo X é a sua variável de estudo. No gráfico acima a variável no eixo X é QI para a população mundial. A área entre dois pontos dessa curva representa A PROBABILIDADE DE AO ACASO SE ENCONTRAR UM VALOR ENTRE ESTES DOIS PONTOS. Assim, o valor 13.6% significa que há 13.6% de chance de se encontrar ao acaso uma pessoa na população mundial com QI entre 70 e 85, 13,6% é a área embaixo da curva entre os pontos 70 e 85, que é de 0,136, convertida em percentagem (multiplicada por 100). Veja que os valores extremos, QI ACIMA DE 145 e QI ABAIXO DE 55 são muito raros, ou seja, possuem baixa probabilidade de serem encontrados por acaso (0.1%). É assumindo que sua variável segue uma curva assim, ou de uma lógica similar, que é possível se estimar quão provável é se encontrar aquele tamanho de efeito observável por acaso.

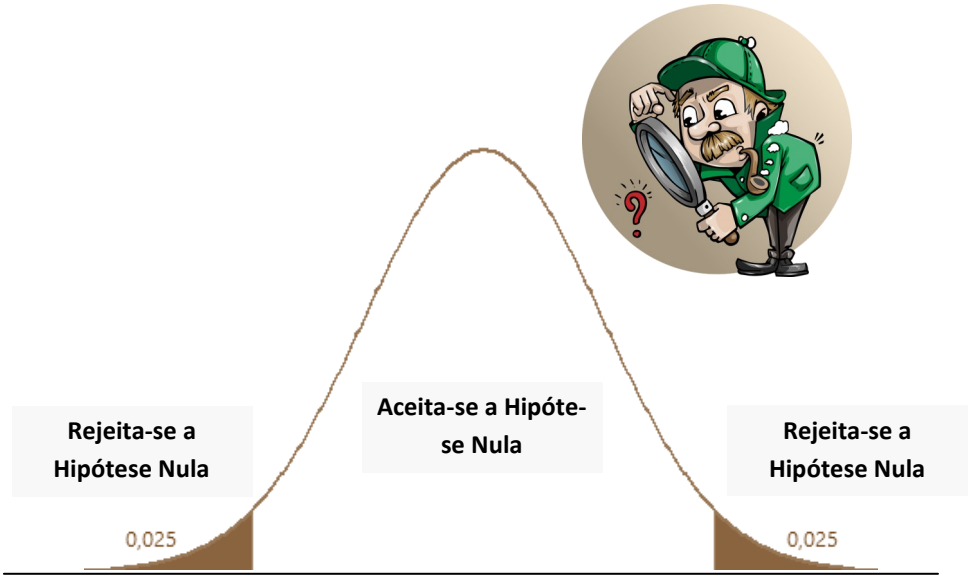


Na prática, seus dados coletados nunca seguem perfeitamente a forma de sino de uma curva normal, no gráfico na parte de cima desta página está o que seria esperado em teoria, mas na prática quando plotados através de um gráfico chamado histograma (que nada mais é que um gráfico onde no eixo X está uma variável seguimentada em faixas de valores e no eixo Y quantas vezes ocorreu na amostra cada faixa de valor), seu gráfico se parece mais com o gráfico da curva de baixo na figura acima. Então, é bom aqui notar que inferências estatísticas (sempre dentro do contexto da estatística clássica frequentista) são por definição aproximações, são tentativas de buscar se estimar probabilidades que permitam aceitar ou rejeitar a hipótese nula.



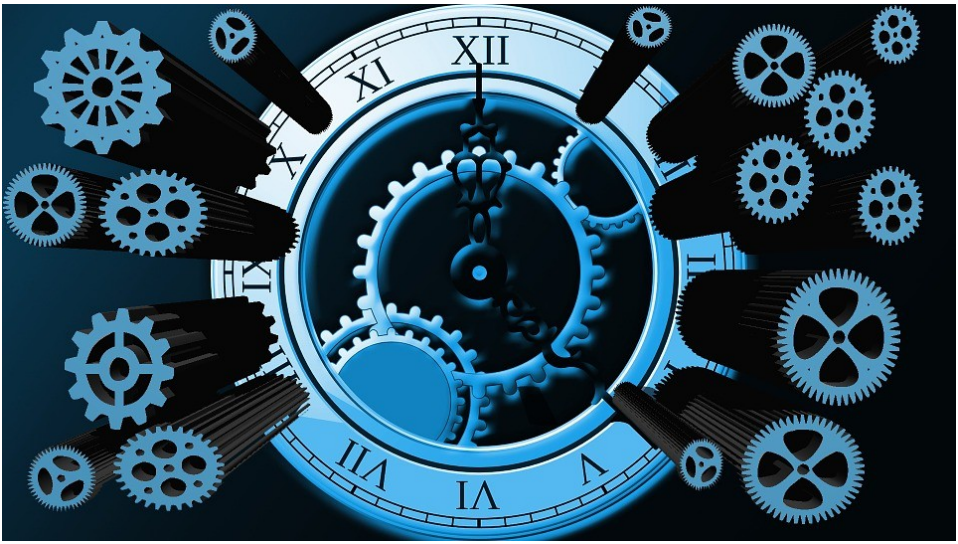
É comum estudantes calcularem manualmente a estatística do teste, e buscarem em tabelas, a partir de um α fixado, para dado número de graus de liberdade, um valor extremo de estatística de teste que os indique uma região de aceitação ou rejeição da hipótese nula. Hoje em dia há softwares que fazem tudo isso em frações de segundo após uns poucos cliques no mouse. O importante é claro, é ter consciência plena do que se está fazendo.

Assumindo que sua variável segue uma dada distribuição, é razoável supor que por consequência lógica a estatística do teste também seguirá uma determinada distribuição de probabilidade. O que se faz em disciplinas mais tradicionais de estatística inferencial é calcular manualmente: a estatística do teste a partir de suas peças de informação (seus dados), e procurar em tabelas de referência, para um α fixado, e para um certo valor de graus de liberdade, qual a chance de encontrar uma estatística de teste igual ou mais extrema àquela encontrada por você nos seus dados. O que não se traduz geralmente de forma clara ao estudante é que o que ele está fazendo é basicamente: buscando encontrar qual a chance de achar por simples acaso um efeito similar (maior ou mais extremo) que aquele denotado em seus dados por simples acaso. Geralmente têm-se o que se chama de valor crítico da estatística do teste, que é o valor que diz onde fica a zona de aceitação ou rejeição da hipótese nula, ou seja, você compara a estatística do teste calculada a partir de seus dados, com o valor crítico, e a partir dessa comparação se rejeita ou aceita a hipótese nula.



Acima temos um gráfico de distribuição de probabilidade contendo as zonas de aceitação e rejeição da hipótese nula. A área determinada entre quaisquer dois pontos do eixo X é uma integral, e se calculada, representa a probabilidade de se obervar um valor naquela faixa de ocorrência dado que a hipótese nula seja verdadeira. As áreas rachuradas em ambos os lados do gráfico representam probabilidades baixas de que se observe valores naquelas faixas mais extremas. Acima escolheu-se um alfa de 0,05. Se o pesquisador optar por um alfa digamos de 0,01, as área rachuradas seriam empurradas ainda mais para o extremo da curva, então, a hipótese nula só seria rejeitada para valores ainda mais extremo. Assim, quando se reduz o alfa, o pesquisador está dizendo que só vai descartar o acaso como explicação (rejeitar a hipótese nula) caso o efeito encontrado seja realmente marcante.

A maioria das curvas de distribuição de probabilidade de testes estatísticos de hipótese são derivadas a partir da curva normal, ou se relacionam diretamente com ela, mas em todas elas a lógica é a mesma: calcular a estatística do teste para o meu conjunto de dados, e ver a partir de uma função de distribuição de probabilidade teórica qual a chance de encontrar, dado que a hipótese nula seja verdadeira, um valor igual ou mais extremo que aquele encontrado por meio de meu conjunto de dados.



A ESTATÍSTICA DO TESTE

A estatística do teste é um número abstrato que tenta retratar o efeito que você está observando. Voltemos ao nosso exemplo dos meios de cultura de fungos, meio enriquecido em nutrientes, e meio pobre em nutrientes. Temos duas biomassas médias, digamos que sejam 6,5g para o meio pobre em nutrientes, e 8,4g para o meio rico em nutrientes. Uma estatística de teste simples que você poderia criar sozinho seria uma média menos a outra, isso é: 8,4-6,5=1,9. Poderíamos em sua homenagem chamar essa estatística de estatística V, V de VOCÊ. Então nesse caso a estatística V seria 1,9. Vejamos se essa sua estatística V funciona. A estatística de um teste deve ser um número que de algum modo, aumente a medida que aumente o efeito nos dados, no caso, o efeito aqui é a diferença de rendimento das biomassas, ou seja, sua estatística V deveria aumentar a medida que aumentassem as diferenças entre as biomassas. Ótimo, ela cumpre esse primeiro quesito. Mas temos um problema: COMO ATRIBUIR UMA PROBABILIDADE DE OCORRÊNCIA AO ACASO para cada um dos valores que sua estatística V poderia assumir? Para isso seria necessário, primeiro, assumir que a variável biomassa segue uma dada distribuição de probabilidade, e depois através de uma série de artifícios e habilidades matemáticas conseguir construir uma distribuição de probabilidade para sua estatística V para diferentes níveis de significância α, e a partir daí ter um valor de P para aceitar ou rejeitar a hipótese nula. Se conseguir isso você criou um novo teste estatístico de hipótese, parabéns :).

Felizmente, muitos bons estatísticos já fizeram isso por nós. E mais, elaboraram estatísticas bem mais sofisticadas que apenas a diferença entre as médias. Um exemplo é a estatística t, que é própria do teste t, que é o teste universalmente mais utilizado para se comparar duas médias. A estatística t para se comparar duas médias de dois grupos distintos, como no caso de nosso experimento, se define da seguinte maneira:

$$t = \frac{media_1 - média_2}{\sqrt{\frac{desvio_1}{n_1} + \frac{desvio_2}{n_2}}}$$

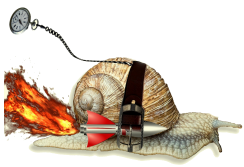
Onde na fórmula acima desvio refere-se ao desvio padrão, para cada um dos grupos, 1 e 2, e n refere-se ao tamanho da amostra para cada um dos grupos (um grupo pode ter um n digamos de 15 placas, o outro um n de 20 placas, o ideal é ter o mesmo n em cada grupo, mas se eles são diferentes isso não implica que o teste não possa ser feito).

Vamos economizar um pouco de símbolos e retratar isso de uma forma mais elegante:

$$t = \frac{\mu_1 - \mu_2}{\sqrt{\frac{{s_1}^2}{n_1} + \frac{{s_2}^2}{n_2}}}$$

onde μ, s e n, representam respectivamente as médias, desvios, e tamanho amostral, para cada grupo. Essa é a estatística do teste t. Esse é um excelente exemplo de estatística de teste! Veja que interessante, quanto maior forem as diferenças entre as médias, maior será o valor em módulo da estatística t, isso você observa olhando para o numerador da equação acima. Assim, em nosso exemplo, quanto maior for a diferença entre as biomassas, maior será o valor da estatística t. Quanto menores forem os desvios padrões, maior também será o valor da estatística t. Isso faz muito sentido, porque, quando uma variável tem uma faixa de variação muito ampla para os dois grupos (s_1 e s_2 elevados), significa que os dois grupos possuem muitos elementos com valores parecidos para aquela variável, então provavelmente não se tratam de grupos "distintos". Já os valores de *n* amostrais também são importantes, pois pode haver um desvio padrão muito grande em um grupo, mas isso será balanceado pelo n amostral, pois quanto mais se coleta informação, mais diferenças pode-se observar, então, o simples fato de coletar mais (aumentar o *n*) não faz com que a estatística t seja inflada. Do contrário, ela seria maior não porque a diferença entre os grupos é maior, mas simplesmente porque se coletou mais, o que a deixaria meio inapropriada ao propósito de retratar em seu aumento um aumento no efeito mensurado.

Você não precisa na prática memorizar nenhuma fórmula de estatística de teste. E no caso de comparação de médias o mais importante é você entender que apesar de ser representada por um número abstrato, ela visa retratar quantitativamente o efeito de diferença entre os grupos, e possui uma distribuição de probabilidade, que associa uma probabilidade de ocorrência para cada valor ou faixas de valores que ela pode assumir.





Você não precisa na prática memorizar nenhuma fórmula de estatística de teste, nem fazer cálculos manuais.



Graus de Liberdade

Graus de liberdade são peças independentes de informação. O termo independente significa dizer que o que acontece com uma de suas unidades amostrais não afeta o que acontece com outra unidade amostral para aquela variável, assim, cada unidade amostral sua é uma réplica independente do fenômeno que está sendo analisado. A estatística frequentista parte de uma pressuposição platônica curiosa, a de que na natureza existe uma coisa chamada média para uma população, ela existe e está lá. Assim, por exemplo, imagine os cães do seu bairro, existe uma média de peso para os cães de seu bairro, e uma média de peso para os cães de sua cidade, estado, país, continente, mundo. Esses números existem, não são meros artefatos de uma manipulação de dados seguida de alguns cálculos, são coisas reais, isso faz parte da estrutura filosófica da estatística clássica.

Quanto maior o n amostral, mais peças de informação independentes, mais graus de liberdade, e consequentemente maior o poder de inferência.

Bom, vamos fazer uma brincadeira imaginária curiosa. Imagine que você é Deus, e está criando um mundo. Nesse seu mundo, existirão apenas 2 cães ok? ANTES DE CRIAR A POPULAÇÃO DE CÃES VOCÊ COMO DEUS VAI FIXAR A MÉDIA DE PESO DESTA POPULAÇÃO. Digamos que você escolha o número 6kg. Ótimo, então criará uma população de dois cães, a média do peso será 6kg.



O primeiro cão pode pesar o valor que você quiser, mas o segundo cão não, pois a média já foi fixada. Portanto, o peso do segundo cão DEPENDE do peso do primeiro cão, uma vez que o parâmetro MÉDIA da população, já existe e está fixado! Assim, se o primeiro cão pesar 2kg, o segundo cão obrigatoriamente vai ter que pesar 10kg, para que a média seja igual a 6kg (10kg+2kg)/(2kg). Assim, se sua amostra tem tamanho *n*, você nunca possui *n* peças independentes de informação, sempre que uma média é fixada, você perde uma peça de informação independente, já que ela se torna dependente do valor da peça anterior. Se estender esse raciocínio verá que para cada grupo onde existe uma média, você possui sim *n* peças de informação, mas apenas *n-1* peças independentes de informação!

Essas peças independentes de informação são o que chamamos de GRAUS DE LIBERDADE. Para as comparações em testes estatísticos sempre perdemos um grau de liberdade para cada parâmetro fixado. Quando estamos comparando duas médias, perdemos 2 graus de liberdade para o *n* total amostral. Quanto mais graus de liberdade temos, mais peças de informação temos para conduzir uma inferência estatística, e temos mais poder analítico. Agora, veja que fato curioso: vimos que perdemos 2 graus de liberdade quando queremos comparar duas médias, então se nosso *n* amostral for igual a 2 (um individuo em cada grupo, ou uma réplica em cada grupo) e queremos comparar 2 médias, quantos graus de liberdade temos? 2-2=0. Temos ZERO GRAUS DE LIBERDADE, OU SEJA: não temos peças de informação suficientes para se fazer uma comparação por meio de um teste estatístico!

Então, o conceito de graus de liberdade é importante também porque ele reflete de forma indireta na análise o tamanho do *n* amostral que foi utilizado . Digamos que você olhe um estudo onde duas médias foram comparadas, e os graus de liberdade da análise sejam mostrados no trabalho como sendo igual a 48. Isso significa que o *n* amostral total foi de 50, pois perde-se 2 graus de liberdade numa comparação de 2 médias.



A estatística frequentista parte de uma pressuposição platônica curiosa, a de que na natureza existe uma coisa chamada média para uma população, ela existe e está lá, e tudo o que fazemos é inferi-la.

CAPÍTULO 4

PODER DOS TESTES E ERROS DE INFERÊNCIA

O poder de um teste estatístico e os erros de inferência tipo I e tipo II.





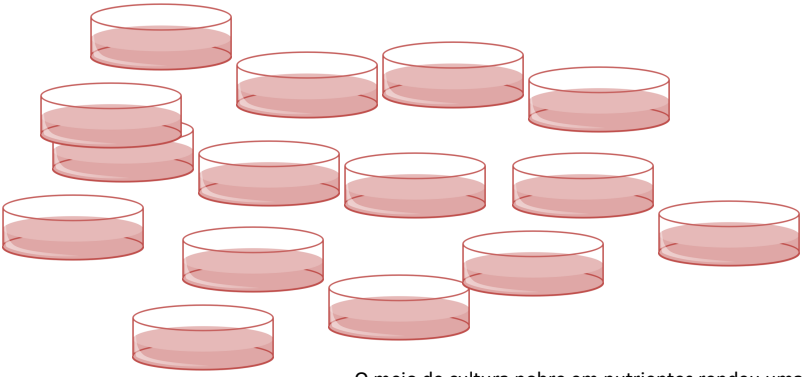
Você performa um experimento e quer saber se aquele efeito denotado em seus dados é de fato real, ou apenas um artefato do acaso. O teste estatístico é a ferramenta que você possui para averiguar isso. Pense no teste estatístico como se fosse uma espécie de lupa, que amplia uma dimensão da realidade pra você. A olho nu, sem essa lupa, você não consegue enxergar se existe um efeito real ou não. Com o auxílio dela a visão melhora consideravelmente. Se existe um efeito real, você quer capturá-lo. Quer que essa lupa tenha resolução suficiente para capturar esse efeito. Mas e se o efeito for pequeno demais para a resolução de sua lupa? Isso pode acontecer. A capacidade de um teste estatístico capturar um efeito quando ele existe é chamada de poder do teste. O poder do teste depende diretamente dos graus de liberdade. Quanto mais graus de liberdade temos, maior o poder do teste. É como se a capacidade de capturar o efeito fosse a resolução da lupa, e quanto mais graus de liberdade maior é essa resolução. É por isso que sempre buscamos ter amostras grandes. O perigo de se trabalhar com um *n* amostral pequeno, é que pode existir um efeito na natureza e você não conseguir capturá-lo. Nessa analogia, é como se a sua lupa estivesse com uma resolução baixa. O efeito está lá, mas é sutil demais para a resolução dela, então você não captura o efeito.

O que acontece quando você aumenta exageradamente a resolução da lupa? Pense no seguinte: o que aconteceria se com um microscópio de varredura eletrônica você buscasse olhar para diferenças entre duas partes da superfície de uma mesa perfeitamente polida? Você vai encontrar diferenças de polimento! Mas são diferenças tão pequenas que podem ser desprezíveis para o tipo de escala ou de pergunta que se está trabalhando. De modo análogo, quando o *n* amostral é grande demais, encontra-se diferenças em todo canto, todos os testes tendem a ser significativos, os valores de p em comparações tendem a ser pequenos, e as hipóteses nulas tendem a ser sempre rejeitadas, pois é como se a sua lupa estivesse com elevada resolução e dizendo: bom, aqui tem efeito sim! No entanto, aquele efeito pode ser completamente desprezível para sua pergunta de pesquisa.

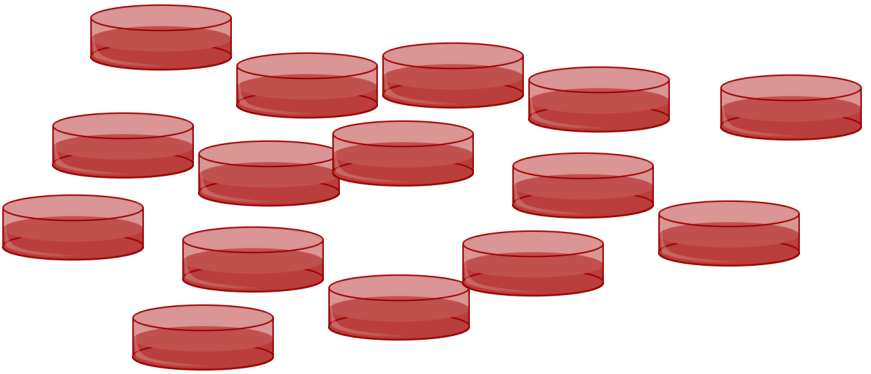


Uma analogia útil é pensar um teste estatístico como sendo uma espécie de lupa, que o permite enxergar coisas na realidade, que a olho nu não seriam possíveis. O poder de resolução dessa lupa é influenciado diretamente pelos graus de liberdade, consequentemente pelo *n* amostral.

Se o *n* amostral é grande demais, a lupa tem um poder exagerado, e detecta diferenças que não são relevantes de um ponto de vista científico. Se o *n* amostral é pequeno demais, a lupa não tem resolução suficiente, e pode não detectar coisas que na realidade existem.



O meio de cultura pobre em nutrientes rendeu uma biomassa média de 5,5g



Já o meio de cultura enriquecido em nutrientes rendeu uma biomassa média de 5,51g. Se o n amostral foi muito elevado o teste capturará essa diferença e o p será significativo.

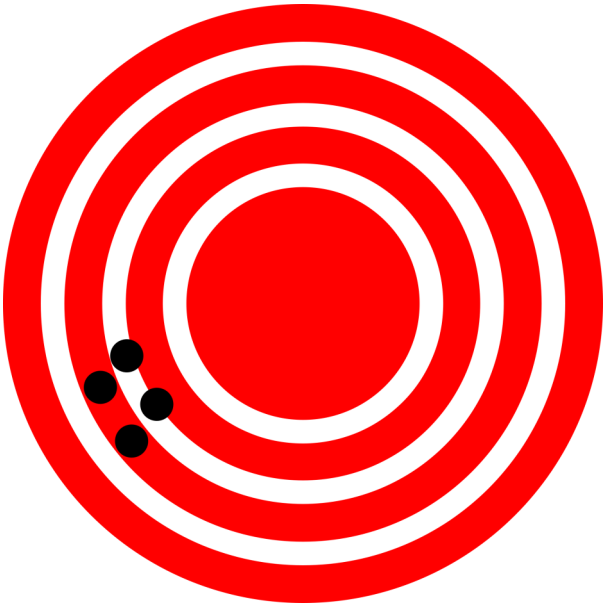
Voltemos ao exemplo do meio de cultura. Digamos que o meio rico seja de fato melhor para o crescimento dos fungos, mas que na realidade a diferença de rendimento de biomassa seja de apenas 0,01 gramas entre o meio rico e o meio pobre em nutrientes. Pode ser uma diferença de rendimento completamente desprezível em termos práticos, mas se você possuir instrumentos de medida acurados o bastante e um *n* amostral absurdamente elevado, o teste estatístico vai capturar essa diferença, o p será significativo. Então você ficaria na embaraçosa situação de ter que discutir uma diferença de 0,09 gramas como indicada como significativa por um teste estatístico, quando na prática, seria totalmente desprezível em termos de diferença de produtividade entre os dois meios. **Isto seria uma diferença estatisticamente significativa mas cientificamente irrelevante.**



Então, é muito importante notarmos aqui que há uma distinção entre DIFERENÇA ESTATÍSTICAMENTE SIGNIFICATIVA e DIFERENÇA CIENTIFICAMENTE SIGNIFICATIVA. Quem define se um resultado é cientificamente relevante não é o teste estatístico, é você como pesquisador. As imagens das flores acima, podem ser estatisticamente bem distintas, mas seriam cientificamente relevantes estas distinções? Depende da pergunta, depende do contexto, depende de você pesquisador.

Um resultado pode ser estatisticamente significativo mas cientificamente irrelevante. E o contrário também pode acontecer, um resultado pode ser cientificamente relevante e estatisticamente não significativo (exemplo: não há diferenças entre duas médias, mas isso ocorre numa situação em que você buscava igualdade entre médias, por exemplo, ao comparar seu meio de cultura com um meio de cultura caro do mercado, esperando que seu meio de cultura renda tanta biomassa quanto o meio de cultura caro vendido no mercado, nesse caso, você espera que NÃO EXISTAM DIFERENÇAS NOS RENDIMENTOS, então, espera um p estatístico alto, espera que qualquer diferença ali observada não seja real, mas sim artefato do acaso, então esse é um resultado estatisticamente não significativo, mas cientificamente muito relevante, pois mostra que seu meio de cultura alternativo é engenhoso e tão eficiente quanto o meio elaborado por uma indústria de meios de cultura, **esse é o caso onde sua hipótese científica é a hipótese nula!**).

Portanto, quando um *n* amostral é grande demais, sua lupa (teste estatístico) tem resolução demais, virou um microscópio de varredura eletrônica, e têm-se *o paradoxo da estatística: quando o n amostral é grande demais, todos o valores de p em comparações tenderão a ser significativos*. Quando o *n* é pequeno demais você corre o risco de não capturar efeitos, quando eles na verdade existem. Assim, observe que mesmo com toda a sofisticação matemática, os testes estatísticos não são perfeitos. Mesmo que seu *n* amostral seja ideal, ainda assim pode acontecer de um teste estatístico não capturar um efeito quando ele existe, e ainda pode acontecer de um teste estatístico indicar a você que um efeito existe, quando ele na realidade não existe. Esses erros estatístico recebem uma classificação, conforme a figura que se segue.



Embora acertem na maior parte das vezes, as vezes os testes estatísticos falham, e conduzem o pesquisador a erros, há 2 tipos principais deles conforme vistos na tabela abaixo.

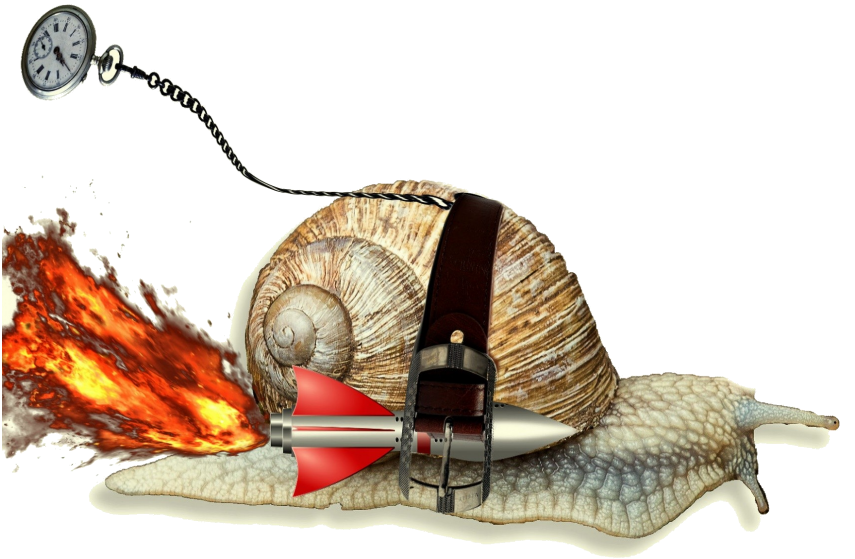
NA REALIDADE H_0 é verdadeira	**NA REALIDADE H_0 é falsa**
Teste diz que H_0 é verdadeira (ACERTOU)	Teste diz que H_0 é falsa (ACERTOU)
Teste diz que H_0 é falsa (ERRO TIPO I)	Teste diz que H_0 é verdadeira (ERRO TIPO II)

Conforme podemos ver na tabela acima, há dois tipos de erro: Erro Tipo I e Erro Tipo II. O mais grave é o erro tipo I, é quando você diz que um efeito existe, quando ele não existe. Exemplo: “Este meio de cultura rende mais”, quando não rende, “Esse medicamento controla o colesterol”, quando não controla. O erro tipo II é menos grave, é quando existe um efeito e você não consegue capturá-lo, isso geralmente ocorre quando se tem um *n* amostral muito baixo, pois não se tem graus de liberdade suficientes, então sua “lupa” (em nossa analogia) tem baixa resolução, e não consegue enxergar um efeito, embora ele exista. Quando tentam tirar conclusões olhando apenas para dados brutos sem utilizar testes estatísticos, as pessoas correm um sério risco de cometerem erro tipo I, o mais grave.

CAPÍTULO 5

TEST T PARA AMOSTRAS INDEPENDENTES

Executando o teste t para amostras independentes em softwares estatísticos e interpretando adequadamente os resultados.

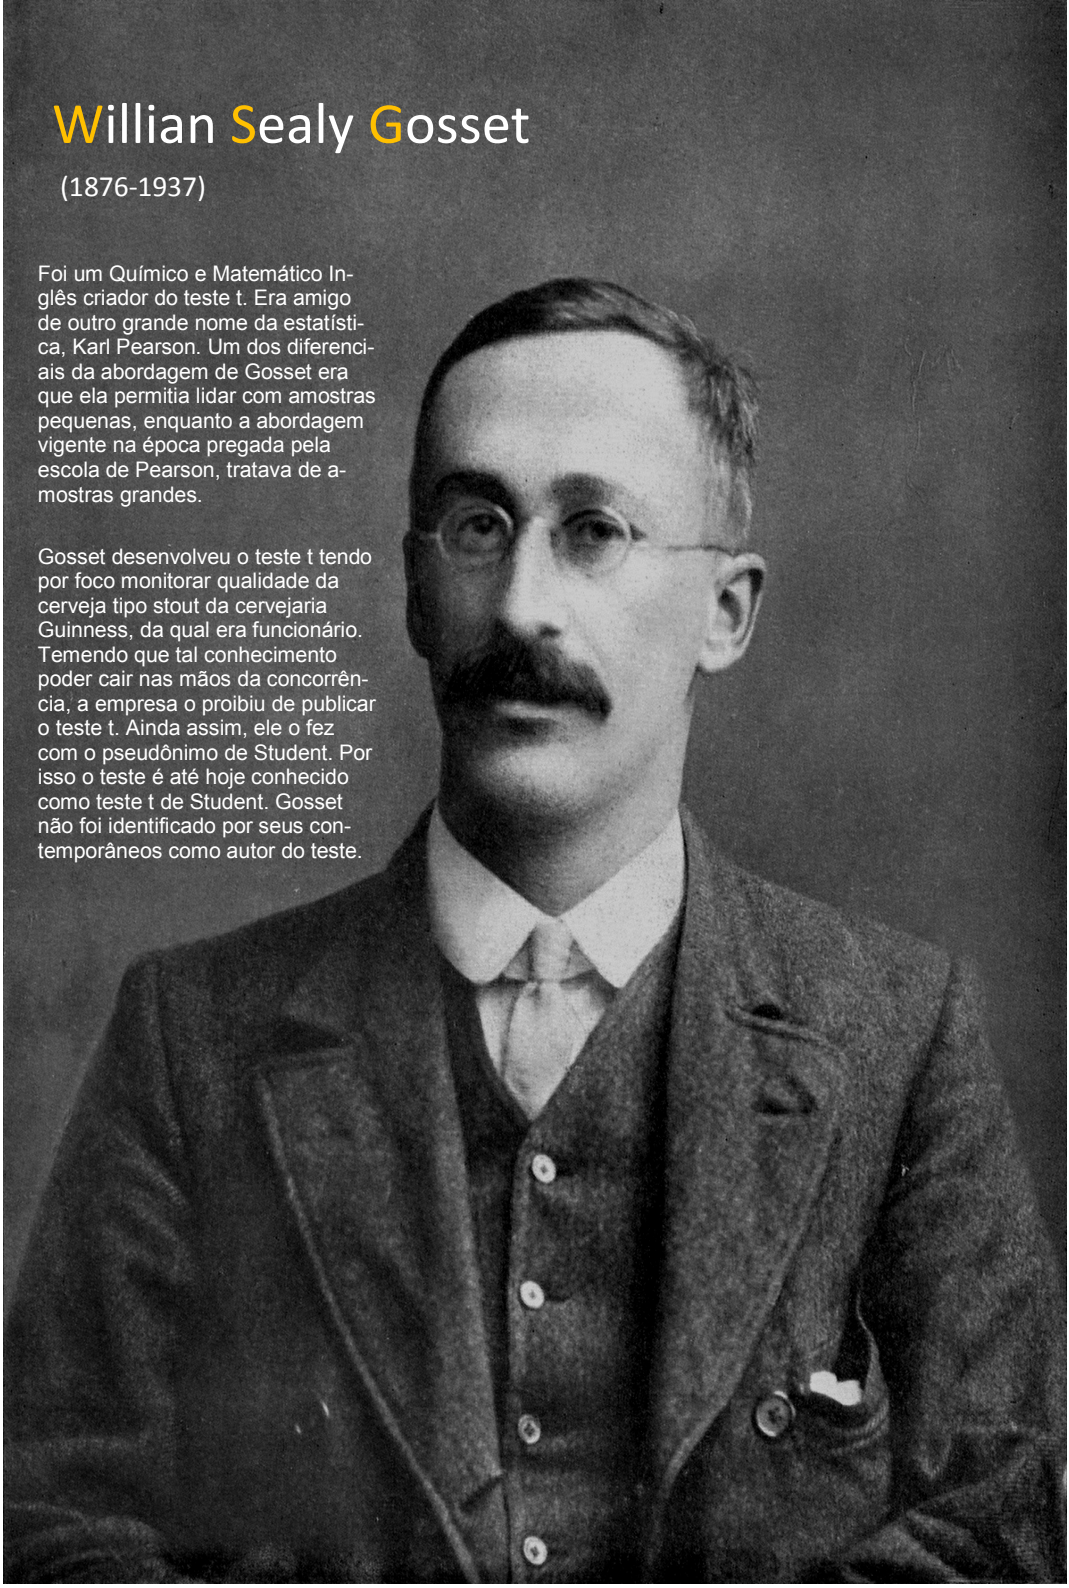


Willian Sealy Gosset

(1876-1937)

Foi um Químico e Matemático Inglês criador do teste t. Era amigo de outro grande nome da estatística, Karl Pearson. Um dos diferenciais da abordagem de Gosset era que ela permitia lidar com amostras pequenas, enquanto a abordagem vigente na época pregada pela escola de Pearson, tratava de amostras grandes.

Gosset desenvolveu o teste t tendo por foco monitorar qualidade da cerveja tipo stout da cervejaria Guinness, da qual era funcionário. Temendo que tal conhecimento poder cair nas mãos da concorrência, a empresa o proibiu de publicar o teste t. Ainda assim, ele o fez com o pseudônimo de Student. Por isso o teste é até hoje conhecido como teste t de Student. Gosset não foi identificado por seus contemporâneos como autor do teste.





Quando quer comparar duas médias você tem basicamente 3 situações.:

1) *São duas médias de dois grupos distintos*, como por exemplo o experimento dos fungos em meios de cultura pobre e rico em nutrientes que vimos até o momento.

2) *É o mesmo grupo, só que em momentos diferentes no tempo* (caso mais frequente daquilo que se chama amostras dependentes ou pareadas).

3) *Você quer comparar a média de um grupo com outra média fixa que seria esperada.*

Para todos esses casos a técnica mais poderosa que temos dentro da estatística frequentista é o teste t. Sempre que quiser comparar duas médias, ele é **A** ferramenta.

Vamos iniciar primeiro aprendendo a interpretar um teste t, e só depois executando ele. Conforme vimos até o momento, todo teste estatístico tem 3 elementos: Valor de P, Estatística do teste, e Graus de Liberdade.

Vamos começar com o teste t para amostras independentes. Ele compara duas médias de dois grupos distintos. Conforme vimos na sessão anterior, sempre perdemos um grau de liberdade para cada parâmetro fixado na análise, assim em um teste t para amostras independentes perdemos sempre dois graus de liberdade, um para cada média. Se o *n* amostral é de 50, um teste t para amostras dependentes terá GL=48. Digamos que você abra agora um artigo científico para ler, e lá o autor compara duas médias, e nos resultados tem o seguinte: t=2.67, GL=28, p=0,001, sob um nível de significância de 5% (valor de α).

Como interpretar isso?

Antes de mais nada vamos olhar para o valor de p. Se ele for menor que 0,05, isso quer dizer que NÃO HÁ DIFERENÇAS SIGNIFICATIVAS ENTRE AS MÉDIAS, então você aceita a hipótese nula, as médias são iguais, qualquer diferença vista nos dados é simplesmente fruto do acaso. Como aqui o p foi menor que 0,05 podemos rejeitar a hipótese do acaso, a hipótese nula, e discutir as diferenças entre as médias no estudo.


Ao interpretar qualquer teste
estatístico comece olhando
direto para o P!



De forma mais simples: p<0,05, posso discutir as diferenças entre as médias, não é acaso. Já para p>0,05, o acaso pode ser suficiente para explicar o fenômeno, então, não vou nem discutir a hipótese alternativa, pois não posso descartar o acaso como explicação.

Olhemos com mais detalhe esse *output*: t=2.67, GL=28, p=0,001. Aqui, t é a estatística do teste, um número abstrato, que pode ser positivo ou negativo, e vai mudar de estudo pra estudo, de dado pra dado, de caso pra caso, e se obtém a partir da seguinte fórmula, já explanada na página 30:

$$t = \frac{\mu_1 - \mu_2}{\sqrt{\frac{{s_1}^2}{n_1} + \frac{{s_2}^2}{n_2}}}$$

Um t positivo de 2.67 significa uma diferença moderada, não tão pronunciada em magnitude, entre as médias. Claro que isso é um pouco subjetivo, as vezes uma diferença pequena em magnitude pode ser cientificamente muito interessante.

GL são os graus de liberdade da análise, em inglês se representa pelas letras df (degrees of freedom). No caso do teste t para amostras independentes perde-se duas peças de informação do *n* amostral total, já que há duas médias sendo comparadas, então, como GL=28, isso implica que o *n* amostral deste estudo foi de 30 réplicas.



Então apenas olhando para esse *output*: t=2.67, GL=28, p=0,001

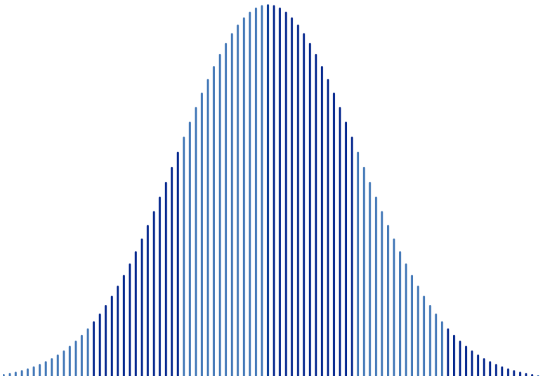
nós podemos inferir que as médias comparadas são diferentes, e essa diferença não pode ser atribuída ao acaso, a diferença é moderada, e havia um n amostral de 30 réplicas no estudo.

Assim, antes de fazer nosso primeiro teste t já vamos saber como interpretar qualquer teste t que virmos pela frente. Digamos que o teste tenha gerado um *output* assim: t=1.57, GL=38, p=0,67. O que significa? primeiro olhamos o valor de p, ele é alto, bem maior que 0,05, ou seja, não podemos rejeitar a hipótese nula, não podemos descartar o acaso como explicação, então, o resultado é estatisticamente não significativo, não vamos discutir as diferenças entre as médias, vamos as considerar como sendo iguais! Como assim sendo iguais se nos dados elas são diferentes? Significa que muito provavelmente essa diferença entre as médias mostradas pelos dados são artefato do acaso. GL=38 significa que o estudo teve um n amostral de 40 réplicas. Agora que já sabemos interpretar o teste t, vamos entender seus pressupostos.

Os pressupostos do teste t para amostras independentes

1) As amostras são independentes e provêm de dois grupos distintos
2) A variável dependente é mensurada numa escala contínua (no nosso caso essa variável é biomassa)
3) A variável em estudo deve seguir uma distribuição normal (normalidade)
4) As variâncias devem ser aproximadamente iguais nos dois grupos (variâncias homogêneas).

O primeiro pressuposto implica em ter peças de informação independentes para inferência, se os dados foram coletados corretamente ou o experimento corretamente planejado ele se cumpre. O segundo pressuposto significa que você precisa de uma variável quantitativa contínua, no nosso caso biomassa, da qual serão tomadas as médias dos dois grupos. Normalidade significa que a distribuição dos dados deve seguir



uma curva em forma de sino, a curva normal. Homogeneidade de variâncias implica que os dados devem ter espalhamentos em tornos das médias similares nos dois grupos. Ou seja, se em um grupo os dados forem todos próximos da média, no outro grupo assim também deve ser. Se em um grupo houver grande espalhamento dos dados em torno da média, no outro grupo assim também deve ser (ao menos aproximadamente). Não pode haver um grupo em que os dados sejam todos muito próximos da média e outro onde eles são distantes, isso significa que um grupo tem maior variação nos dados que o outro, o que fere o pressuposto de variâncias homogêneas.

É importante não ter dados discrepantes ou *outliers* em seu conjunto de dados, uma vez que estes podem afetar a estimativa não apenas no teste t, mas em qualquer teste estatístico. Dados discrepantes são como "aberrações" que ocorrem em seu conjunto de dados, podem ser devidos a problemas experimentais, na coleta de dados, ou em alguns casos ocorrerem por fazerem mesmo parte do sistema, então, não colocaremos ausência de *outliers* aqui como um pressuposto, embora alguns autores prefiram assim colocar.

Mãos a obra. Podemos fazer nosso primeiro teste t. Para tal utilizaremos um conjunto de dados com os pressupostos já verificados, mais na frente aprenderemos como verificar os pressupostos, por hora vamos direto ao teste. Vamos comparar os dois meios de cultura, o rico em nutrientes e o pobre em nutrientes para rendimento da biomassa.

Nossas hipóteses são:

Hipótese Nula (H_0): Não há diferenças entre médias de biomassas nos dois meios, quaisquer diferenças apresentadas são artefato do acaso.

Hipótese Alternativa (H_1) : Por propiciar os elementos metabólicos estruturais essenciais para o crescimento de fungos, espera-se que o meio de cultura enriquecido propicie maior rendimento de biomassa que o meio de cultura pobre em nutrientes.

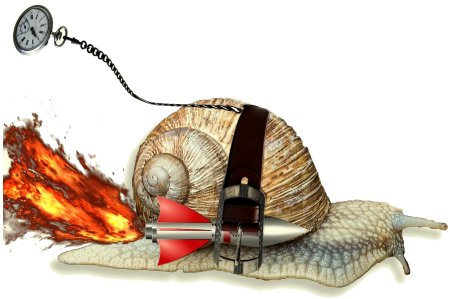
Então temos 2 MÉDIAS, DE DOIS GRUPOS para serem comparadas, vamos utilizar O TESTE T para AMOSTRAS INDEPENDENTES.

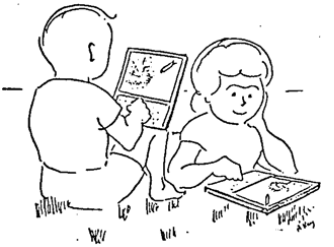
Não vamos fazer NENHUM CÁLCULO MANUAL, como já temos toda a base conceitual clara, vamos apenas colocar os dados em um software, dar alguns cliques, observar o *output* contendo t,GL e p, e interpretar com profundidade a análise a partir daí.

Usaremos os seguintes Dados:

Meio Enriquecido	Meio Pobre
9	7
8	6
8	6
7	5
7	5
8	7
6	5

Veja que cada célula nesta tabela representa a biomassa extraída de uma placa de nosso experimento. Vamos agora nas sessões seguintes aprender como inserir esses dados em um software estatístico e executar as análises.





QUAL SOFTWARE IREMOS UTILIZAR

Há inúmeros pacotes estatísticos. Na minha opinião os melhores nessa fase de aprendizado são aqueles que unem interface gráfica intuitiva e de fácil uso a elevado poder analítico. A maioria dos softwares que seguem esses dois quesitos são softwares comerciais. Há muitos softwares gratuitos, porém são feios, de uso as vezes tosco, e apresentam resultados de forma muito confusa. Utilizaremos aqui o software Statistica, da Statsoft. Se não possui ele em seu computador, você pode fazer o download de uma versão completa funcional por 30 dias no link logo abaixo:

http://www.statsoft.com.br/download.php

Após baixar o arquivo basta executar o setup e seguir os passos de instalação que são bem simples e intuitivos. Após instalado o software abra o Statistica.

OPERANDO O SOFTWARE PARA ANÁLISE DE DADOS

A interface do Statistica é bem simples e intuitiva. Ao abrir o software feche qualquer menu de atalho ou apresentação que aparecer. Em seguida clique em FILE/NEW e em seguida clique em OK. Você verá uma planilha com 10 colunas e 10 linhas na sua tela.

Você pode digitar os dados diretamente sobre as células, assim como faria em uma planilha de Excel. As variáveis recebem os nomes padrões Var1, Var2... até a última coluna, para nomear as colunas basta dar um duplo clique sobre as mesmas. Sua planilha de dados deve ficar assim:

STATISTICA - [Data: Spreadsheet2* (10v by 10c)]

File Edit View Insert Format Statistics Data Mining Graphs Tools Data Window Help

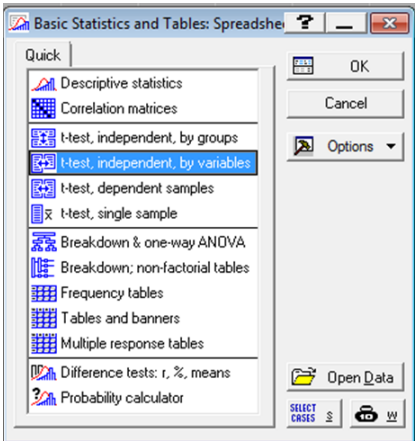
Add to Workbook Add to Report Add to MS Word

Arial 10

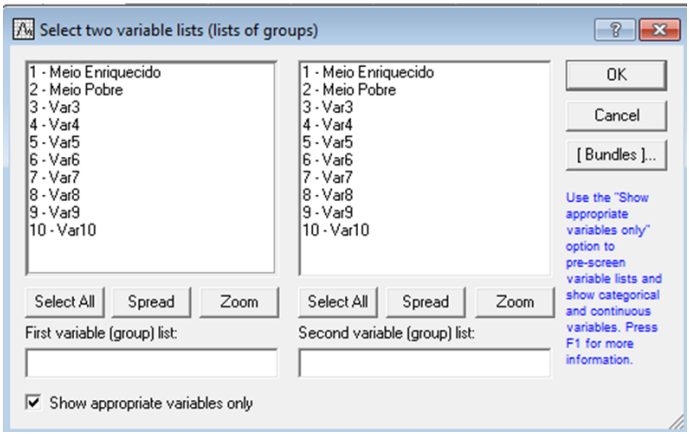
	1 Meio Enriquecido	2 Meio Pobre	3 Var3	4 Var4	5 Var5	6 Var6	7 Var7	8 Var8	9 Var9	10 Var10
1	9	7								
2	8	6								
3	8	6								
4	7	5								
5	7	5								
6	8	7								
7	6	5								
8										
9										
10										

Feito isso agora é bem simples.

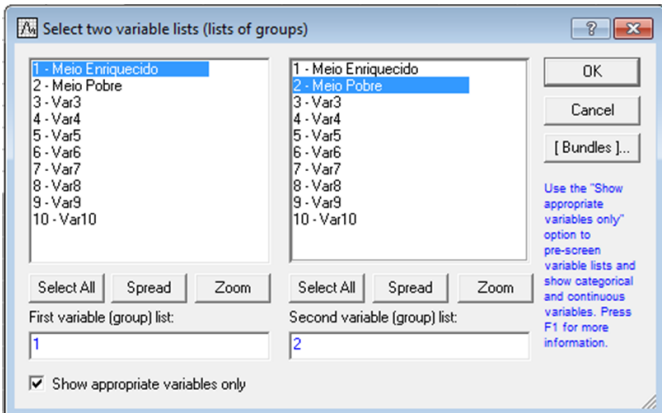
Clique no menu *Statistics,* em seguida em *BASIC STATISTIC TABLES,* e marque a quarta opção de cima pra baixo, chamada *T-TEST, INDEPENDENT, BY VARIABLES*.



Agora clique sobre o botão com setinha verde chamado *VARIABLES(GROUPS),* deve aparecer a seguinte tela:



Na caixa em branco da esquerda selecione Meio Enriquecido, na caixa da direita selecione Meio Pobre, de modo a ficar assim:



ÓTIMO, está pronto para realizar seu primeiro teste t? Basta agora clicar no botão OK. E em seguida no botão *summary: T-TESTS*.

Vai aparecer pra você o seguinte *output*:

T-test for Independent Samples (Spreadsheet2)
Note: Variables were treated as independent samples

Group 1 vs. Group 2	Mean Group 1	Mean Group 2	t-value	df	p	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
Meio Enriquecido vs. Meio Pobre	7,571429	5,857143	3,416969	12	0,005107	7	7	0,975900	0,899735	1,176471	0,848638

Vamos agora interpretar esses resultados. A princípio não precisamos de todas essas colunas de informações que o software nos fornece, precisamos apenas das 4 primeiras colunas, que têm as médias, o valor de t, os graus de liberdade e o valor de p, assim, vamos nos focar apenas nas quatro primeiras colunas da figura acima:

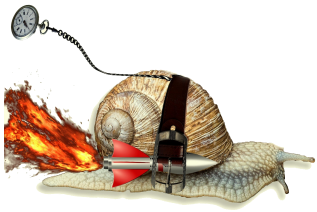
Mean Group 1	Mean Group 2	t-value	df	p
7,571429	5,857143	3,416969	12	0,005107

Isso é tudo o que precisamos. ANTES DE MAIS NADA, quais eram nossas hipóteses? Vou escrevê-las de forma simplificada para relembrarmos:

Hipótese Nula: Não há diferenças entre as médias.

Hipótese Alternativa (Científica): O meio rico em nutrientes propicia maior crescimento.

Mean Group 1	Mean Group 2	t-value	df	p
7,571429	5,857143	3,416969	12	0,005107



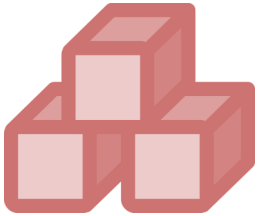
Se o valor de p for menor que 0,05, rejeitamos a hipótese nula. Então a primeira coisa que vamos procurar é o valor de p. Ele está na quarta coluna, conforme pode ver, é bem menor que 0,05, logo, podemos rejeitar a hipótese nula, as médias são diferentes, e a chance dessa diferença ser simplesmente fruto do acaso é muito baixa (p=0,005). Utilizamos de prática apenas três casas decimais para o p após a vírgula, embora os softwares nos forneçam mais casas decimais.

Então podemos discutir as diferenças entre as médias já que descartamos a hipótese nula. Conforme pode ver pela configuração do *output*, ele chama *Group* 1 o grupo de Meio Enriquecido, e *Group* 2 o grupo de meio pobre em nutrientes. Então as duas primeiras colunas fornecem AS MÉDIAS para ambos os grupos, veja que a média maior é a média do grupo 1, sendo esta 7,57g e a média do grupo 2 é 5,85g. QUAL MÉDIA É MAIOR? A média do grupo enriquecido é maior, e podemos discutir essa diferença porque o valor de p foi menor do que 0,05. A coluna seguinte é apenas a estatística do teste t, é um numero abstrato que não tem significado em termos experimentais, mas que segue uma tendência: quanto mais distintos forem os grupos em seu experimento, maior é o valor de t. A coluna seguinte mostra os graus de liberdade, 12, que é nosso n amostral total (14) menos o número de médias comparadas (2).

Na hora de reportar os resultados escrevemos isso tudo em um parágrafo bem simples, do seguinte modo: *A biomassa média foi maior no tratamento enriquecido em nutrientes, 7,57g, em comparação com o tratamento pobre em nutrientes, 5,85g (t=3,417,GL=12,p=0,005).*

Está feito o seu primeiro teste estatístico, feito e interpretado adequadamente. Veja que se o teste permitiu descartar o acaso como explicação, quer dizer que as médias realmente são diferentes (muito provavelmente), agora é com você discutir o porque dessas diferenças (quais hipóteses explicam, os detalhes metabólicos, bioquímicos, etc).

E se o valor de p tivesse sido não significativo, como eu reportaria os resultados? De modo muito similar, mas não descartaria a hipótese nula, portanto, NÃO DIRIA QUE UMA MÉDIA É MAIOR QUE A OUTRA, aceitaria a hipótese nula, e diria o seguinte: "NÃO HOUVERAM DIFERENÇAS SIGNIFICATIVAS NO RENDIMENTO DE BIOMASSA entre os dois tratamentos no presente estudo".



RESUMINDO OS PASSOS:

1) Tenha claro em mente quais são suas hipóteses. Hipótese nula: as médias são iguais. Hipótese alternativa: As médias são diferentes por tais e tais motivos.

2) Copie ou digite os dados no software e nomeie adequadamente as variáveis dando duplo clique sobre o nome das mesmas.

3) Clique no Menu STATISTICS/BASIC STATISTIC TABLES/ T TESTE INDEPENDENT BY *VARIABLES*/ OK.

4) Clique em *VARIABLES* (*GROUPS*), e selecione o primeiro grupo na caixa esquerda, e o segundo grupo na caixa da direita / OK.

5) Clique em SUMMARY: T-TESTS

6) OBSERVE O VALOR DE P na quarta coluna, se ele for menor que 0,05, descarte a hipótese nula, provavelmente não é acaso a explicação.

7) OBSERVE QUAL MÉDIA FOI MAIOR.

8) APRESENTE O RESULTADO mostrando qual média foi maior e mostrando os três elementos do teste estatístico: a estatística do teste, os graus de liberdade, e o valor de p.

Propositalmente o conjunto de dados montado já segue os pressupostos de normalidade e homogeneidade de variâncias, iremos aprender um pouco mais a frente como testar esses pressupostos, e como agir aplicando transformações matemáticas ao conjunto de dados quando eles não são seguidos.

DICAS

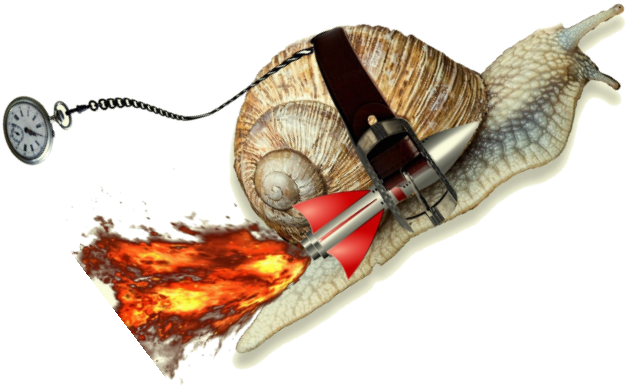
No statistica, quando o output sair todo em vermelho SIGNIFICA QUE O TESTE FOI SIGNIFICATIVO, isto é, P<0,05. Quando o output sair em PRETO, significa que o teste não foi significativo. É apenas uma curiosidade didática do software.

A janela com seus resultados é apenas mais uma janela dentro do Statistica, para alternar entre seus dados e o resultados você pode clicar no Menu Windows, e escolher entre as janelas que quer alternar ou pode usar o atalho ***CTRL+Tab.*** *do teclado ara alternar entre as janelas. O Statistica salva um arquivo somente com seus resultados, e mantém em um arquivo separado os dados*.

CAPÍTULO 6

TESTANDO OS PRESSUPOSTOS

Como testar os pressupostos de normalidade e homogeneidade de variâncias e que transformações usar quando os mesmos não são atendidos.

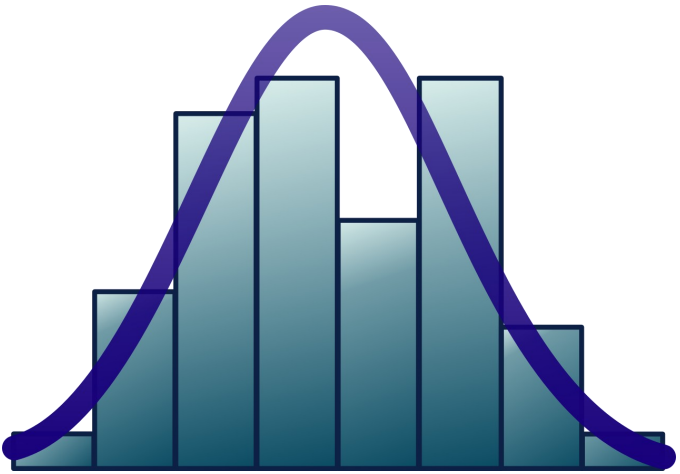




Aprenderemos neste capítulo a como testar os pressupostos de normalidade e homogeneidade de variâncias. Antes disso, vamos apenas mencionar brevemente uma outra vertente interessante da estatística denominada de algoritmos de monte carlo. Veja, você como pesquisador tem como objetivo saber qual a chance da configuração de resultados que encontrou ser devida ao acaso. Uma maneira de conseguir encontrar uma resposta para esta pergunta é: embaralhando seus dados em um computador, e recalculando centenas ou milhares de vezes uma dada estatística, que poderia ser a estatística V que inventamos na sessão anterior (uma média menos a outra), ou qualquer outra estatística. Depois de terminar a simulação com o embaralhamento dos dados, basta contar quantas vezes naqueles dados embaralhados ao acaso, ocorreram resultados de diferenças similares aos seus. O P estatístico é dado aqui simplesmente dividindo o número de vezes que seu resultado ocorreu, pelo número total de resultados gerados pelo embaralhamento. Digamos que em 1000 simulações de embaralhamento dos dados ocorreram 40 diferenças iguais ou maiores que aquelas que você obteve em seus dados. Seu P seria portanto 40/1000, 0,04. A vantagem dessa abordagem computacional é que os dados não precisam atender a pressupostos de distribuição de probabilidade. Ela é uma abordagem que ainda está ganhando terreno, pois seu próprio desenvolvimento e evolução dependeu do advento da computação e ainda depende de habilidades computacionais de programação, coisa que ainda não é muito comum, nem entre pesquisadores. No entanto, fora essa abordagem, precisamos sempre verificar se nossos dados atendem a pressupostos para que as probabilidades possam ser inferidas corretamente. Vamos em frente então.

Já sabemos que o teste t para amostras independentes tem dois pressupostos básicos: os dados seguem uma distribuição normal, e as variâncias são homogêneas. Por ter esses pressupostos ele se encaixa no grupo de testes chamados paramétricos, que fundamentam seus cálculos sob a premissa de validade dessas pressuposições. Vamos aprender nessa sessão como testar cada um destes pressupostos.

Por mais surpreendente que possa parecer, existem testes estatísticos para testar os pressupostos! Quer dizer que eu tenho que fazer um teste estatístico antes de fazer um teste estatístico? SIM :). Parece confuso? A lógica é bem simples: **quando encontramos diferenças entre coisas que estão sendo comparadas, sempre devemos nos perguntar: qual a chance de isso ser devido ao acaso?** Olhe por exemplo para o histograma abaixo:



Você verá que os dados não seguem perfeitamente uma distribuição normal, eles não se encaixam perfeitamente na forma da curva. HÁ, PORTANTO, UMA DIFERENÇA ENTRE O QUE OS DADOS SÃO E O QUE A CURVA NORMAL TEÓRICA PREDIRIA QUE FOSSEM, qual a chance dessa diferença ser fruto do acaso? Há um p estatístico para isto! Há portanto um teste de hipótese que pode ser usado para testar a normalidade dos dados, na verdade vários deles. No caso específico de testes de normalidade eles são um pouco problemáticos, a inspeção visual, embora subjetiva, é aceita como um método razoavelmente válido para teste de normalidade.

Vamos aprender aqui como fazer as duas coisas, primeiro uma inspeção visual da normalidade, depois como fazer o teste de Shapiro Wilk, para verificar se os dados seguem ou não uma curva normal.

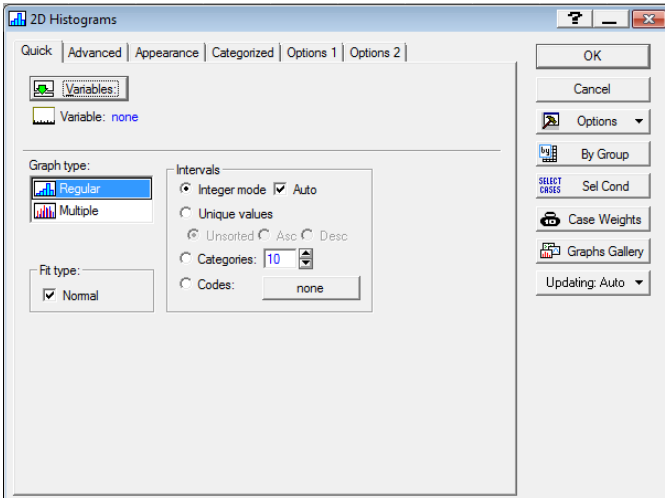
Construindo Histogramas, inspeção visual

Um Histograma é um gráfico que plota seus dados de um modo muito interessante. Ele coloca no eixo X classes de valores para sua variável, e no eixo Y a frequência de ocorrência (uma contagem) para cada uma daquelas faixas de valores.

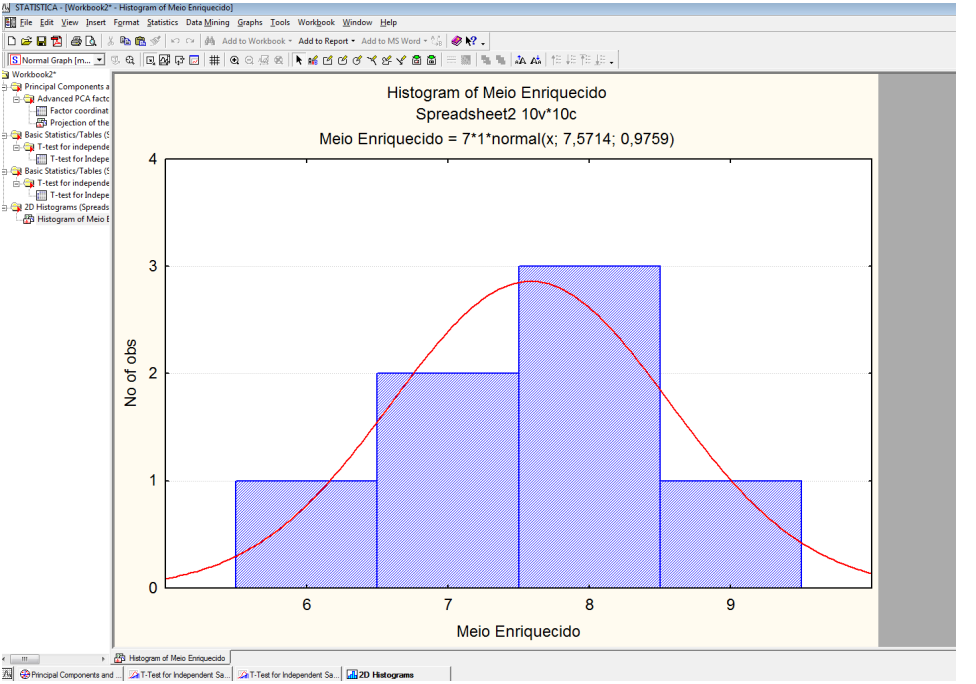
Traçar um Histograma no Statistica é muito simples. Abra o Statistica e certifique-se que na planilha esteja nosso conjunto de dados anterior:

Meio Enriquecido	Meio Pobre
9	7
8	6
8	6
7	5
7	5
8	7
6	5

Agora, para traçar um histograma basta clicar no menu GRAPHS/HISTOGRAMS. Em seguida aparecerá a seguinte tela:



Agora clique em *VARIABLES*, escolha Meio Enriquecido e depois clique em OK. E agora clique em OK novamente. Está pronto o seu histograma:

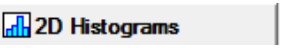


O eixo Y de qualquer histograma é sempre frequência ou contagens de ocorrências. Neste caso o título está abreviado em inglês: *Number of Observations* (No of obs). Se você der um duplo clique sobre o título verá que pode modificá-lo. Aliás pode personalizar com duplo clique todo o gráfico no Statistica, alterar fundo, cores, padrões, tudo.

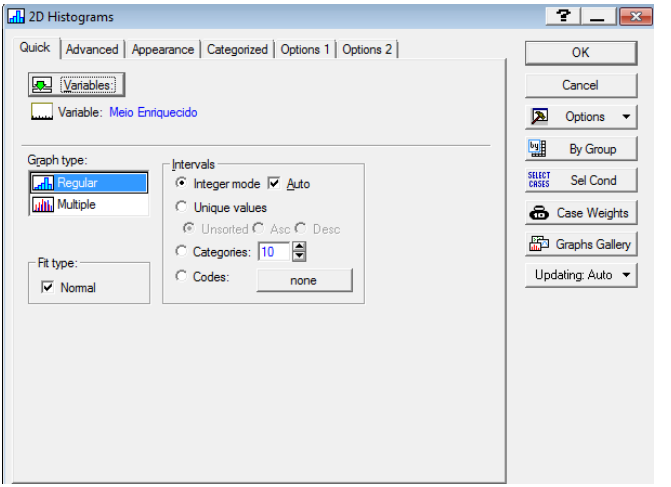
Conforme dito anteriormente, para muitos autores a inspeção visual é suficiente como método de averiguação de normalidade dos dados. Olhe para o gráfico acima. As barras em azul estão razoavelmente encaixadas abaixo da curva? SIM. Então os seus dados possuem sim um aspecto de curva normal, isso é suficiente para que possa avançar tranquilo quanto a esse pressuposto.

MAS, há uma forma alternativa, que alguns consideram como mais rigorosa de testar se seus dados seguem ou não uma distribuição normal, é através do teste de normalidade de Shapiro Wilk. Ele basicamente vai fornecer a você um p estatístico para testar a hipótese nula de que não há diferenças entre seus dados e a curva normal, ou seja: seus dados vêm de uma curva normal. Aqui você quer que a hipótese nula seja aceita, pois quer que seus dados e a curva normal sejam uma coisa só, que não haja diferenças significativas entre seu conjunto de dados e o que seria uma curva normal. Portanto, queremos um p>0,05 para o teste de shapiro Wilk..

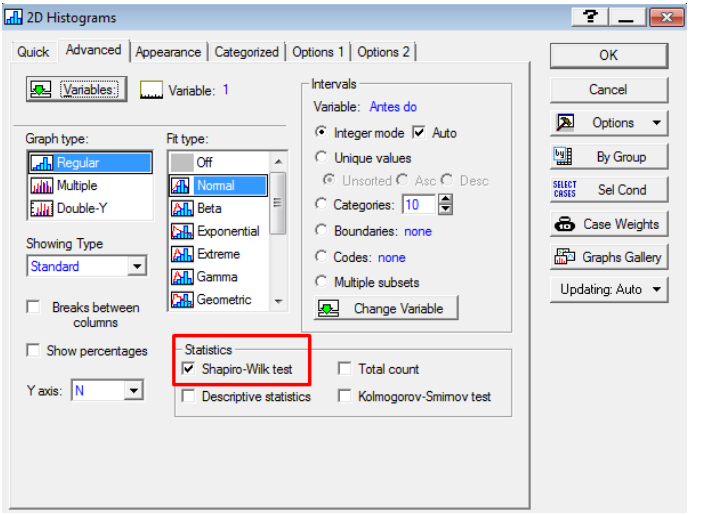
Para executar o teste de Shapiro Wilk basta clica na aba 2D HISTOGRAMS que está na parte inferior da sua tela.



Você retornará para esta janela:

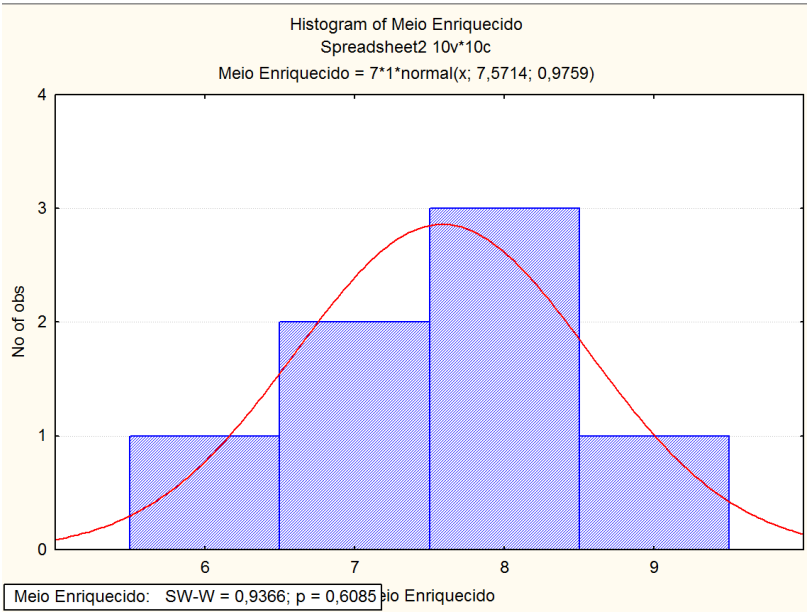


Agora clique na aba ADVANCED, segunda aba na janela acima, terá sua tela assim:



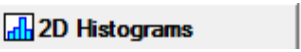
Basta marcar a caixa de diálogo SHAPIRO-WILK TEST assinalada na figura acima e clicar em OK.

Você verá o mesmo histograma anterior, mas na parte inferior dele haverá A ESTATÍSTICA DO TESTE e o valor de P, para o teste de Shapiro Wilk. A estatística do teste de Shapiro Wilk é representada pelo símbolo SW-W, quanto menor for este valor, menor são as diferenças entre seus dados e a distribuição normal teórica. Repare que o valor de p foi bem alto, p=0,608, ou seja, a hipótese nula de que não há diferenças entre seus dados e a curva normal, ou melhor: de que seus dados provêm de uma curva normal, não pode ser rejeitada, logo, os dados seguem uma distribuição normal.

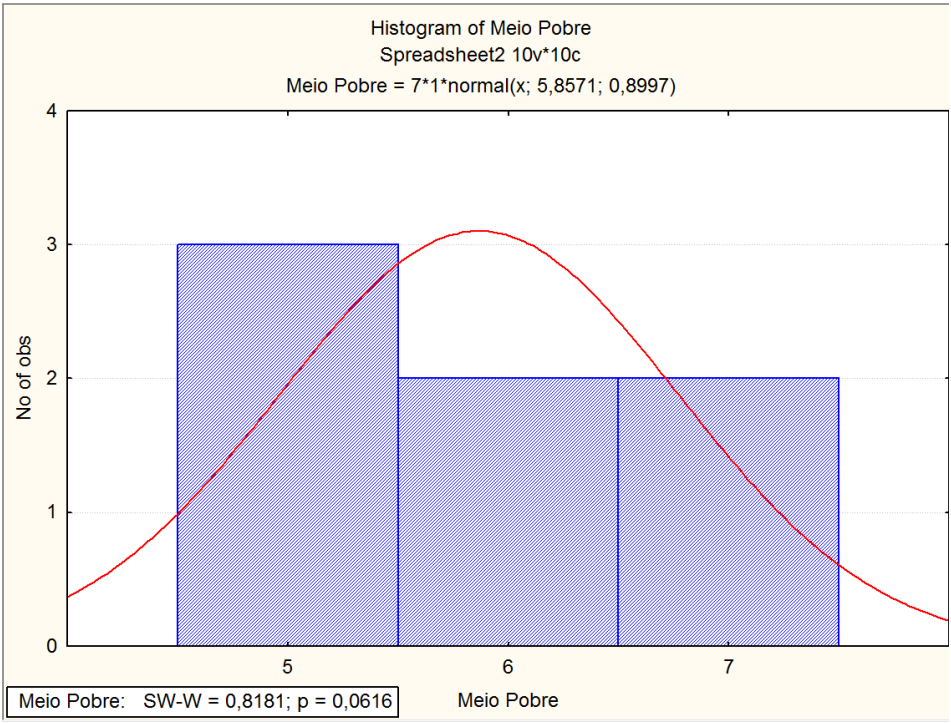


Para um dos grupos temos os dados seguindo aproximadamente uma distribuição normal. Então para o grupo Meio Enriquecido não temos problemas quanto ao pressuposto de normalidade.

Falta agora testar o mesmo para o grupo Meio Pobre. Para isso não precisa repetir todos os passos anteriores, há um atalho bem simples. CLIQUE NA ABA INFERIOR 2D HISTOGRAMS, novamente, representada pelo ícone abaixo:



Agora clique em *VARIABLES*, escolha MEIO POBRE, clique em OK e depois OK novamente. Obterá o histograma abaixo:



Veja que visualmente os dados do tratamento Meio Pobre não se encaixam tão perfeitamente a curva normal quanto os dados anteriores. Ainda assim, se ajustam embaixo da curva de maneira até razoável. Esse é um caso em que por inspeção visual pode-se ter dúvidas, então, olhar para o valor de p do teste de Shapiro Wilk, que neste caso novamente foi não significativo, p>0,05, é uma opção razoável. Então aqui temos também que os dados seguem a distribuição normal, uma vez que a hipótese nula do teste de Shapiro Wilk (de que não há diferenças entre seus dados e a curva normal, ou melhor, de que seus dados provêm de uma curva normal) foi aceita.

Já a homogeneidade das variâncias também pode ser testada com um teste estatístico de hipótese. O teste mais comum para essa finalidade é o teste F. Basicamente o teste F tem uma estatística de teste que é a razão entre variâncias, no caso essas variâncias são as variâncias dos dois grupos.

Quanto mais longe de 1 for a estatística F, mais diferentes são as variâncias dos grupos. Novamente aqui, assim como no teste de normalidade, queremos um valor de p elevado, não queremos ver diferenças entre as variâncias, queremos que elas sejam iguais, um p pequeno, menor que 0,05, indicaria diferenças entre as variâncias.

Já é feito automaticamente pelo Statistica o teste F para homogeneidade de variâncias quando se computa o teste t. Revejamos a tabela de saída do teste t, ela possuía muitas colunas:

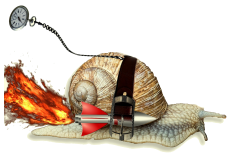
T-test for Independent Samples (Spreadsheet2)
Note: Variables were treated as independent samples

Group 1 vs. Group 2	Mean Group 1	Mean Group 2	t-value	df	p	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
Meio Enriquecido vs. Meio Pobre	7,571429	5,857143	3,416969	12	0,005107	7	7	0,975900	0,899735	1,176471	0,848638

Ficamos até agora apenas com as quatro primeiras colunas, vamos interpretar as demais, o teste F está representado nas duas últimas colunas

Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
7	7	0,975900	0,899735	1,176471	0,848638

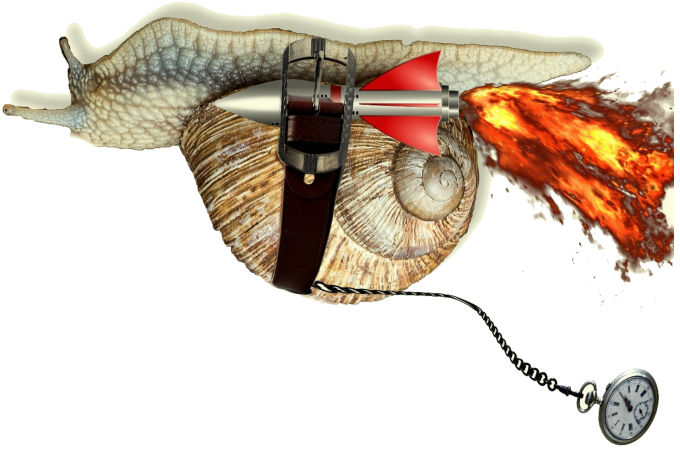
A coluna 5 e a coluna 6 representam os tamanhos amostrais de cada grupo, ambos possuem 7 amostras. Já as colunas 7 e 8 representam os desvios padrões, Standard Deviation, para Meio enriquecido (grupo 1) e Meio Pobre (grupo 2) respectivamente. E AS DUAS ÚLTIMAS COLUNAS, representam A ESTATÍSTICA F e o valor de p para o teste de homogeneidade de variâncias. Veja que o valor de p é bem elevado, p=0,846, indicando assim que a hipótese nula, de que não há diferenças entre as variâncias, deve ser aceita. Assim nossos dados seguem ambos os pressupostos, tanto de normalidade, quanto de homogeneidade de variâncias.

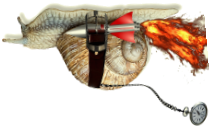


CAPÍTULO 7

TRANSFORMANDO DADOS PARA ATENDER PRESSUPOSTOS E O TESTE T PARA VARIÂNCIAS HETEROGÊNEAS

As duas principais formas de transformação de dados e como aplicá-las, e como aplicar o teste t para variâncias distintas entre os grupos





Uma vez que algum de seus pressupostos não seja atendido, a rigor, não se deve proceder a execução do teste t ou de qualquer outro teste paramétrico. Os dois pressupostos básicos são: normalidade e homogeneidade de variâncias. Se seu conjunto de dados não segue uma distribuição normal, ou não possui variâncias homogêneas, a solução é aplicar uma transformação matemática aos dados.

As duas principais transformações existentes são: logarítmica e raiz quadrada. Na transformação logarítmica você vai utilizar para as comparações não os seus dados originais, mas sim o logaritmo dos seus dados. Do mesmo modo, na transformação de raiz quadrada, você vai trabalhar com a raiz quadrada de seus dados, ao invés de com os dados originais. Há razões teóricas para se usar cada tipo de transformação, por exemplo, a transformação logarítmica é mais indicada quando há variâncias heterogêneas e os desvios padrões são diretamente proporcionais as médias (médias maiores possuem maiores valores de desvio padrão), já a raiz quadrada por exemplo, é mais recomendada quando são as variâncias e não os desvios que são diretamente proporcionais as médias. Mas na prática, o que se faz mesmo é tentar várias transformações para cada conjunto de dados e usar aquela que funcione.

Pensando em termos de imagens, é como se seus dados fossem largos demais para caberem em uma dada caixa, é como se essas transformações criassem um tipo de “achatamento” nos seus dados para caberem nessa caixa e poderem ser processados. No entanto, a hierarquia de magnitude das diferenças é preservada, ou seja, se uma média era maior que a outra, ela continuará sendo após essas transformações. Se atendidos os pressupostos, após executada a análise, o autor deve atentar que a rigor, as médias que estarão sendo comparadas são as médias dos dados transformados, e não as médias originais.

Se mesmo após aplicar as transformações os dados não seguirem os pressupostos, aconselha-se de forma conservadora que se busque uma alternativa não paramétrica equivalente ao teste. As alternativas não paramétricas são testes equivalentes aos testes paramétricos, mas que não possuem pressupostos.

Vejamos como proceder para aplicar a transformação logarítmica e a transformação de raiz quadrada em um conjunto de dados a partir do software Statistica.

Vamos continuar utilizando a mesma ideia dos meios de cultura enriquecido e pobre em nutrientes para fungos, no entanto vamos usar dados distintos do capítulo anterior, carregue para o software estatística os seguintes dados:

Meio Enriquecido	Meio Pobre
8	12
9	3
9	6
6	7
7	6
8	7
9	4

Novamente, nossa hipótese de pesquisa é que o meio enriquecido promove maior biomassa. Vamos então utilizar um teste t para sabermos se a diferença entre as médias é provavelmente fruto do acaso, ou não, mas antes, temos de testar os pressupostos.

Temos dois pressupostos a serem testados:

1) Os dados seguem uma distribuição normal

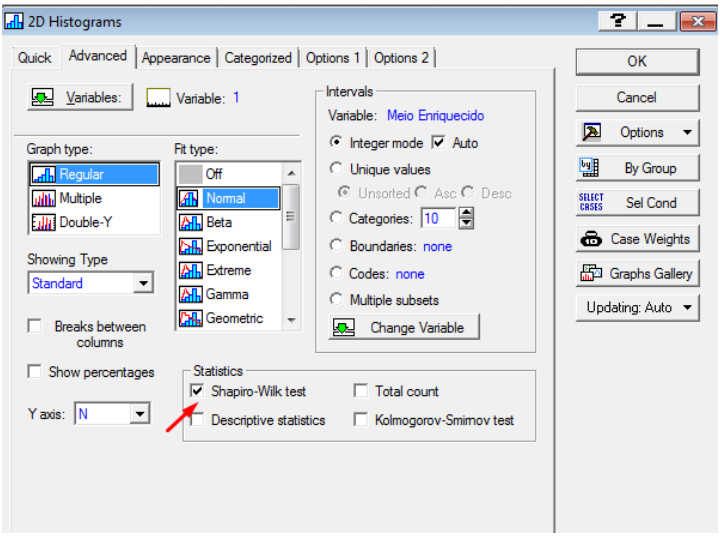
2) As variâncias são homogêneas

Apenas relembrando, o primeiro implica que a distribuição dos dados seguem a curva normal, em forma de sino, e o segundo implica que um grupo não pode ter maior variância do que o outro. Testemos primeiro o pressuposto de normalidade então.

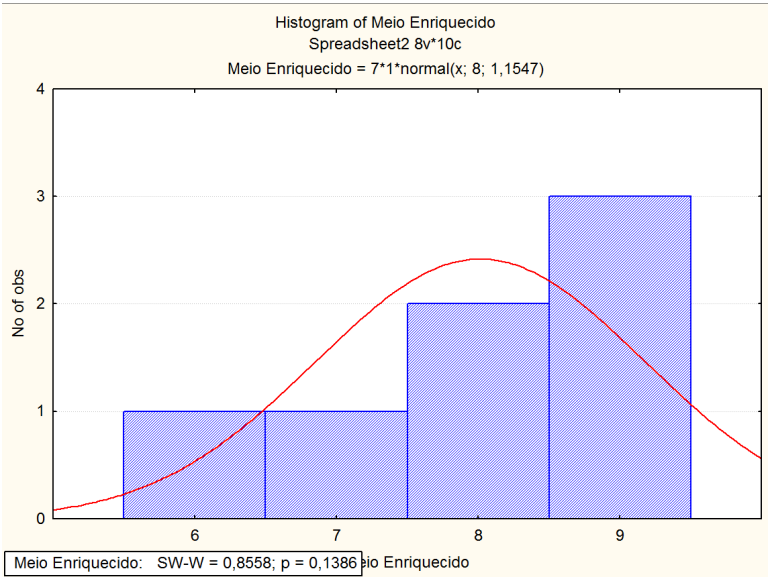
Para isso vamos utilizar o teste de SHAPIRO WILK, juntamente com a inspeção visual via histograma.

Clique em GRAPHS/HISTOGRAMS/ADVANCED/*VARIABLE*S

Selecione a variável Meio Enriquecido, clique em OK. Marque a opção SHAPIRO-WILK TEST conforme assinalado na figura seguinte e por fim clique em OK.

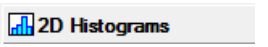


Você verá o histograma abaixo:

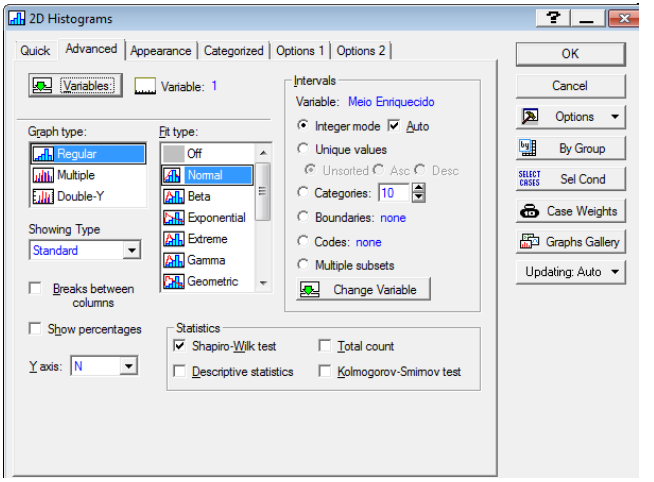


Geometricamente os dados encaixam-se de forma razoável dentro da curva normal, e o P da estatística de Shapiro-Wilk é de 0,138, ou seja, os dados seguem uma curva normal para o grupo Meio Enriquecido.

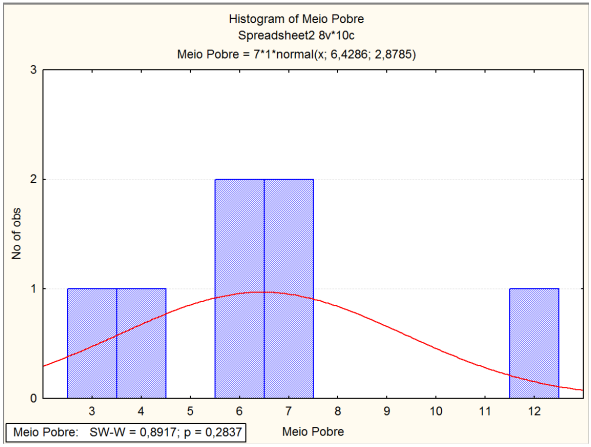
Agora clique na aba 2D HISTOGRAM na parte inferior da tela:



Você retornará para a seguinte janela:



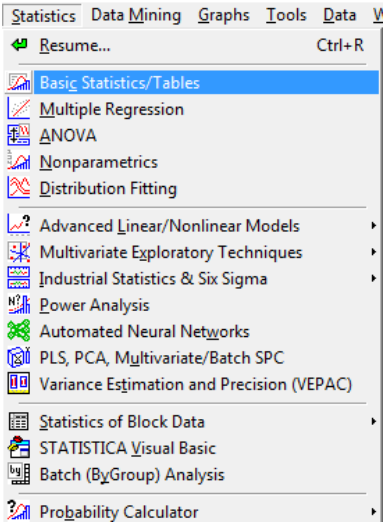
Agora clique em *VARIABLE*S, e selecione Meio Pobre, e por fim clique em OK e OK novamente. Obterá o histograma abaixo:

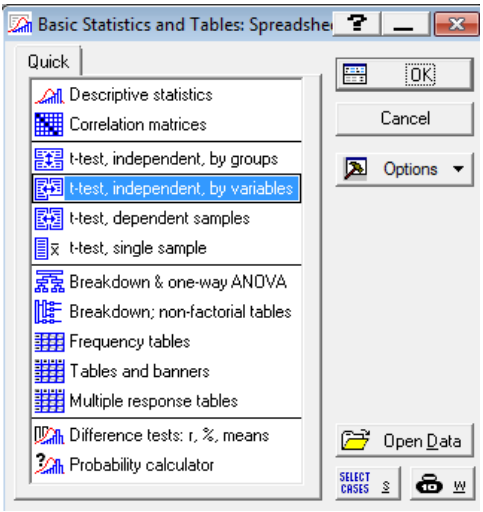


Embora não muito bem encaixados, os dados lembram um jeitão (bem longe) de curva normal, e o p do teste de Shapiro Wilk é 0,283, ou seja, para o grupo Meio Pobre, também temos normalidade.

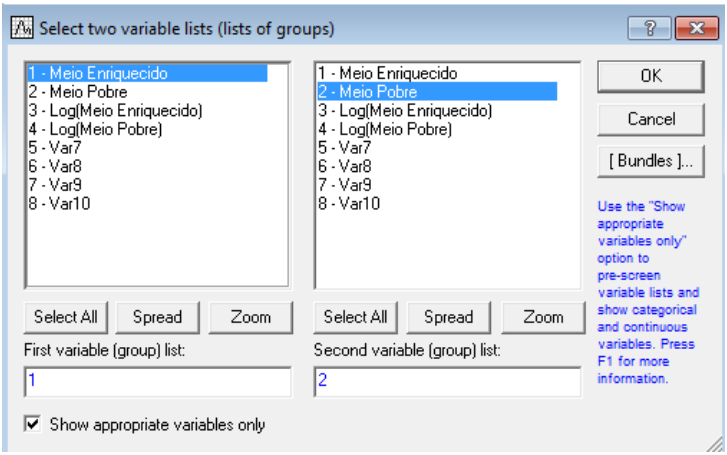
Então para o pressuposto de normalidade tudo ok, vamos então testar o pressuposto de homogeneidade de variâncias.

Para isso vamos seguir os procedimentos para execução do teste t, pois no final do teste já temos o resultado, na última coluna, para o teste de homogeneidade de variâncias. Assim, Clique no Menu STATISTICS/BASIC STATISTIC TABLES/T-TEST, INDEPENDENT BY *VARIABLES*:

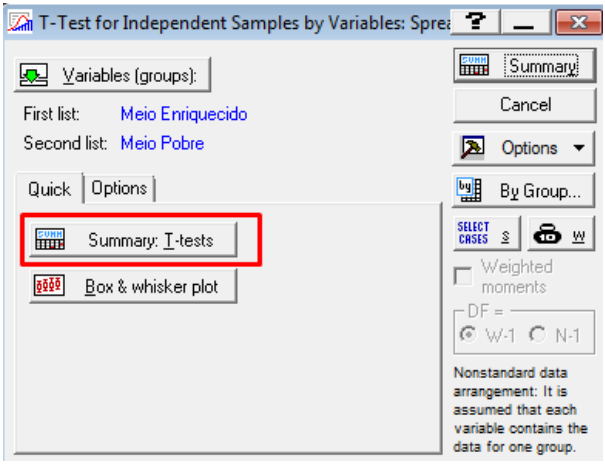




Em seguida clique no botão *VARIABLES* (*GROUPS*) e escolha no lado direito Meio Enriquecido, e na caixinha do lado esquerdo Meio Pobre:



Clique em OK e depois clique em SUMMARY: T-TEST:



Antes de interpretar a análise vamos olhar para a última coluna, que contém o TESTE DE HOMEGENEIDADE DE VARIÂNCIAS. Se esse p na última coluna for menor que 0,05, isso indica que AS VARIÂNCIAS SÃO HETEROGÊNEAS, ou seja, são diferentes. Lembre-se que p pequeno sempre indica que existe algum efeito ou diferença. Isso é ruim, não queremos isso, pois o nosso pressuposto de variâncias homogêneas foi violado.

Mean Group 1	Mean Group 2	t-value	df	p	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
8,000000	6,428571	1,340533	12	0,204899	7	7	1,154701	2,878492	6,214286	0,042805

Focando apenas as últimas 4 colunas da figura acima:

Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
1,154701	2,878492	6,214286	0,042805

E agora, o que fazer?

Agora iremos utilizar uma transformação em nosso conjunto de dados. Vamos ao invés de trabalhar com os dados puros para a execução das análises, trabalhar com um equivalente matemático dos mesmos, obtidos por meio de uma transformação logarítmica dos dados originais.

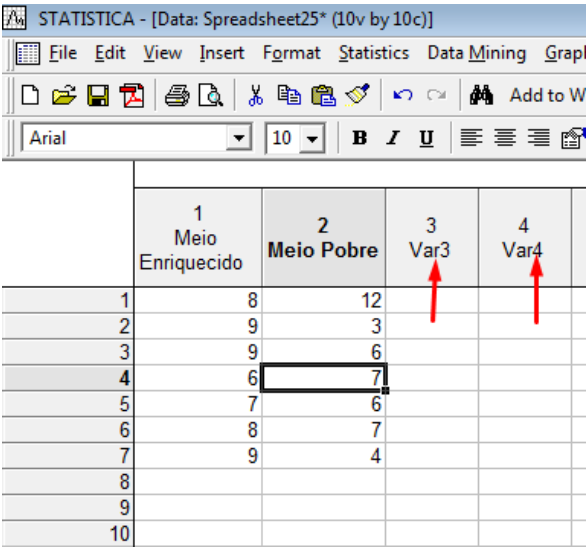
Variâncias heterogêneas significam que um grupo tem muito mais variação que outro. Neste caso, o grupo que tem maior variação é o grupo 2, meio pobre em nutrientes, conforme pode ser visto pela segunda coluna na figura acima através do desvio padrão do grupo 2, que é 2,878, enquanto o desvio padrão do grupo 1 é 1,154.

Por que as transformações funcionam?

Conforme dissemos, pensando com imagens, as transformações "achatam" o seu conjunto de dados. Exploremos isso mais claramente. Por exemplo, imagine a seguinte sequencia de valores, 10,100,1000,10000. A média dessa sequência seria 2777,5. Veja que há grande variância nesta sequência (muita variância implica em valores distantes da média). Veja a distância entre 10 e 2777,5, enorme. Compare isso com a sequência, 1,2,3,4. A média dessa sequência é 2,5. Veja que o espalhamento dos dados em torno da média é muitíssimo menor, compara a distância entre o menor valor, 1 e a média, 2,5, com a distância entre o menor valor da sequência anterior, 10, e a média, 2777,5. Pois bem, vejamos o que o processo de logaritimização faz.

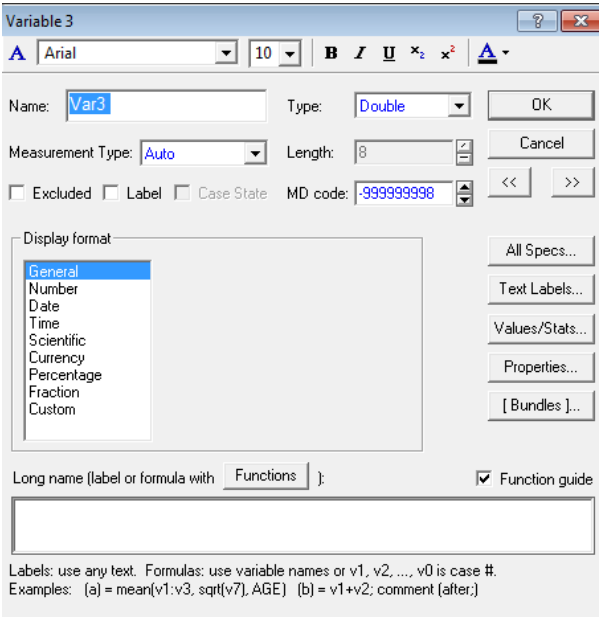
Se calcularmos o Logaritmo na base 10 para cada item da sequência 10,100,1000,10000 obteremos a sequência 1,2,3,4. Então seus dados foram "espremido", "achatados", têm assim o espalhamento em torna da média reduzido drasticamente, logo, a variância é reduzida drasticamente. Como variâncias heterogêneas significa que uma variância é grande e a outra pequena, esse encolhimento das variâncias pode ser uma boa solução ao problema (NEM SEMPRE FUNCIONA, MAS NA MAIOR PARTE DAS VEZES SIM, as vezes mesmo usando as transformações não conseguimos homogeneizar as variâncias).

Vamos criar duas novas variáveis, onde está a variável 3 (Var3) vamos colocar uma variável que será a coluna 1 logaritimizada, e onde está a variável 4 (Var4), vamos colocar uma nova variável, que será a variável 2 logaritimizada.

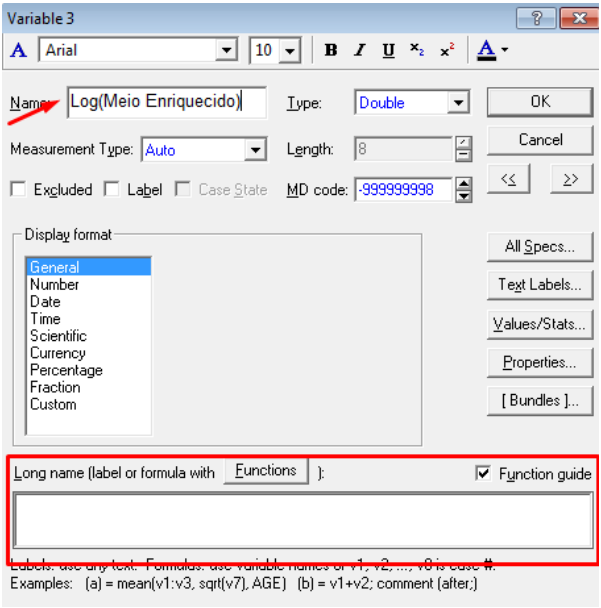


	1 Meio Enriquecido	2 Meio Pobre	3 Var3	4 Var4
1	8	12		
2	9	3		
3	9	6		
4	6	7		
5	7	6		
6	8	7		
7	9	4		
8				
9				
10				

Vamos começar com a variável 3, *Var3.* Dê um duplo clique sobre a variável *Var3* onde as setas indicam na figura acima, deverá aparecer a seguinte tela:



Vamos trocar o nome dessa variável, ao invés de *Var3*, vamos chamá-la de Log(Meio Enriquecido). O nome pode ser qualquer um, vamos usar esse nome específico apenas para organizar bem nossa planilha e termos sempre um entendimento do que estamos fazendo. Assim que digitar o nome da variável clique na caixa indicada pelo retângulo na figura abaixo:

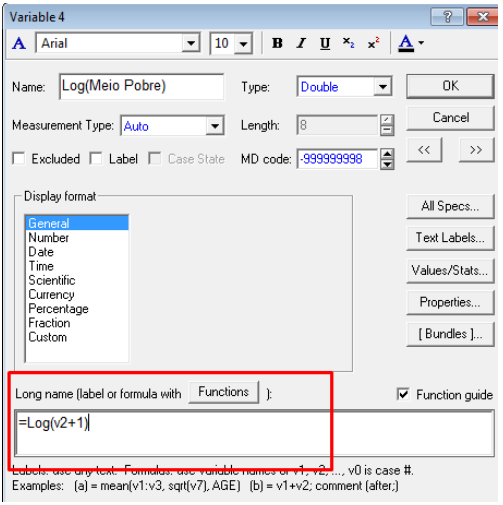


Vamos transformar aqui a coluna 1, denotada como variável Meio Enriquecido (cada coluna é chamada pelo software Statistica de variável). Como o Statistica chama cada coluna de uma variável, em seu cerne ele entende a seguinte linguagem de código para as variáveis: v1=variável 1, v2=variável 2...vn=variável n. Assim, queremos transformar a variável 1, que é meio enriquecido, que o estatística entende como sendo denotada por v1. Assim, na caixa destacada na imagem acima escreva a seguinte fórmula:

=Log(v1+1)

Isso adicionará o valor 1 a cada valor de biomassa da primeira coluna e criará uma nova variável. Usamos a adição de 1 para o caso de haver 0 no conjunto de dados, pois Log(0) não é definido. Agora, basta clicar em OK e depois responder SIM. A Coluna 1 já foi transformada, façamos o mesmo agora para a coluna 2, Meio Pobre.

Para isso, vamos proceder da mesma forma agora para a variável *Var4*. Dê um duplo clique sobre ela, dê a ela o nome de Log(Meio Pobre), conforme mostrado na figura abaixo:



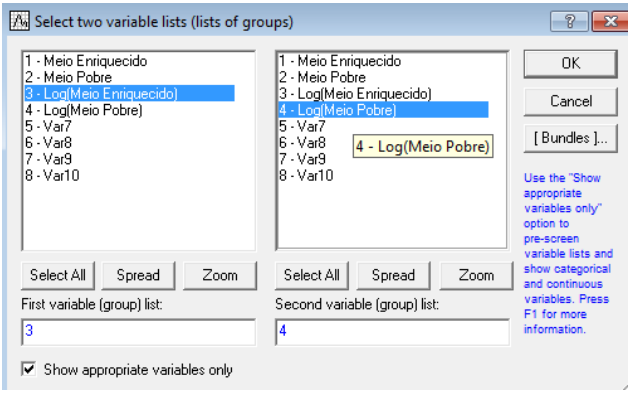
E na caixa em destaque vermelho na imagem escreva a seguinte fórmula:

=Log(v2+1)

Veja que o v2 na fórmula se refere a segunda coluna, que o Statistica entende como sendo a segunda variável da sua tabela de dados. Isso adicionará o valor 1 a cada valor de biomassa da coluna Meio Pobre e criará uma nova variável. Basta clicar em OK e depois responder SIM.

EXECUTEMOS AGORA O TESTE COM AS VARIÁVEIS TRANSFORMADAS

Siga os passos anteriores para execução do teste t: Clique em STATISTICS/BASIC STATISTICS TABLES/ T TEST, INDEPENDENT BY *VARIABLES*. Clique agora em *VARIABLES*. Ao invés de escolher as variáveis originais, como fizemos anteriormente, vamos agora escolher as variáveis logaritmizadas. Assim, na esquerda escolheremos Log(Meio Enriquecido), e na coluna da direita escolheremos (Log Meio Pobre):



Agora basta clicar em OK, e em SUMMARY: T-TESTS. Verá resultado abaixo:

T-test for Independent Samples (Spreadsheet2)
Note: Variables were treated as independent samples

Mean Group 1	Mean Group 2	t-value	df	p	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
2,189651	1,944484	1,625722	12	0,129965	7	7	0,135359	0,375331	7,688699	0,025469

Note que agora o p Variances (p para o teste de homogeneidade de variâncias). MESMO APÓS APLICAR A TRANSFORMAÇÃO LOGARITÍMICA os dados ainda assim não se mostram com variâncias homogêneas.

Podemos tentar a outra transformação possível: raiz quadrada. Para fazer a transformação de raiz quadrada os passos são idênticos a transformação logarítmica, a única diferença é que ao invés de escrever a fórmula =Log(variável +1), você utilizará a fórmula:

=Sqrt(v1)

Para transformar a variável 1 (Meio Enriquecido). E a fórmula

=Sqrt(v2)

Para transformar a variável 2 (Meio Pobre em Nutrientes).

Sqrt é a abreviação de *Square Root* (raiz quadrada) em inglês.

Vamos criar as duas novas variáveis com os nomes: Raiz(Meio Enriquecido) e Raiz(Meio Pobre) respectivamente. Coloque-as nas colunas 5 e 6 de sua tabela, de modo que sua tabela fique assim:

	1 Meio Enriquecido	2 Meio Pobre	3 Log(Meio Enriquecido)	4 Log(Meio Pobre)	5 Raiz(Meio Enriquecido)	**6 Raiz(Meio Pobre)**	7 Var7	8 Var8	9 Var9	10 Var10
1	8	12	2,19722458	2,5649494	2,82842712	3,46410162				
2	9	3	2,30258509	1,3862944	3	1,73205081				
3	9	6	2,30258509	1,9459101	3	2,44948974				
4	6	7	1,94591015	2,0794415	2,44948974	2,64575131				
5	7	6	2,07944154	1,9459101	2,64575131	2,44948974				
6	8	7	2,19722458	2,0794415	2,82842712	2,64575131				
7	9	4	2,30258509	1,6094379	3	2				
8										
9										
10										

Execute agora novamente o teste t usando agora os dados transformados em Raiz Quadrada.

Obterá os seguintes resultados:

Mean Group 1	Mean Group 2	t-value	df	p	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
2,821728	2,684282	0,658936	12	0,522380	7	7	0,210143	0,510294	5,896702	0,048477

Focando apenas nas 4 últimas colunas:

Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances
0,210143	0,510294	5,896702	0,048477

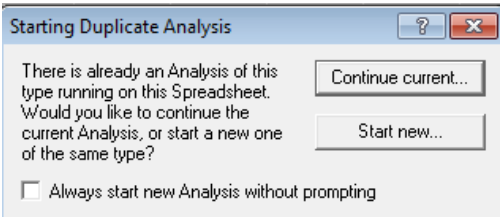
Então novamente, tivemos um p significativo, *isso significa que mesmo após aplicadas as duas transformações mais importantes para este conjunto de dados, ainda assim o pressuposto de homogeneidade de variâncias não pôde ser atendido.*

O que fazer agora?

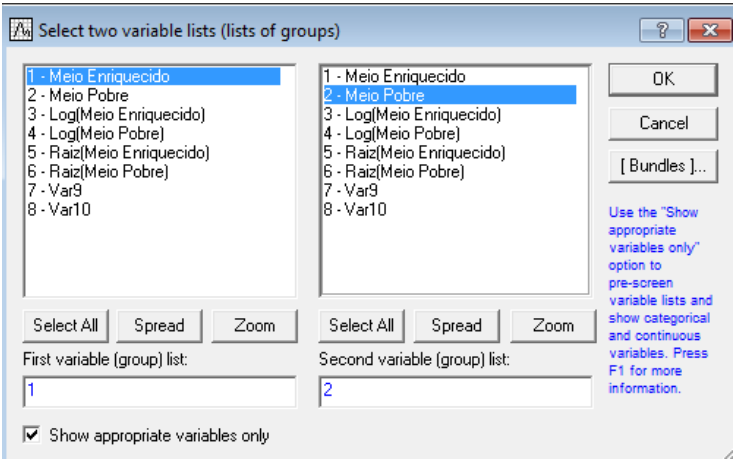
*Existe um teste t para quando as variâncias são distintas, isso é, heterogêneas***.** Ele terá menos graus de liberdade em comparação com o teste t convencional, e portanto, terá menor poder, pois terá menos peças de informação para detectar o efeito que estamos buscando, mas pode ser usado, e na verdade, fornecerá uma estimativa de significância estatística mais precisa que o teste convencional, para o caso de termos variâncias muito distintas, ou heterogêneas. Ele também é útil para *n* amostrais de tamanhos muito diferentes nos dois grupos, não é o nosso caso pois o n amostral é igual em ambos os grupos, mas esse teste também contorna esse problema. Para executar este teste t para variâncias heterogêneas, os passos são similares aos passos que já vimos.

Clique em STATISTICS/BASIC STATISTICS TABLES/

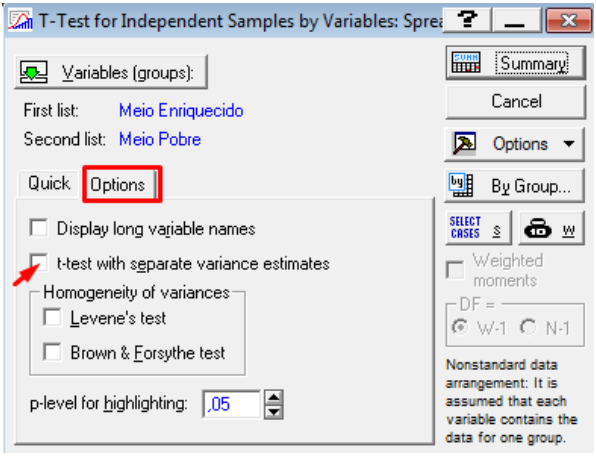
(caso o programa mostre uma caixa de diálogo como a caixa abaixo basta clicar em START NEW), ele está apenas dizendo que você já iniciou o módulo de análises de teste t, então se quiser ele já vai direto para a janela de análises do teste, mas optemos por fazer passo a passo, clique em START NEW).



Escolha T-TEST INDEPENDENT, BY *VARIABLES*. Clique em *VARIABLES*, como antes escolha na caixa da esquerda Meio Enriquecido, e na caixa da direita Meio Pobre:



Em seguida clique em OK. Agora clique na aba OPTIONS, destacada abaixo:



Basta marcar a caixa de diálogo indicada pela seta acima, onde está escrito: T-TEST WITH SEPARATE VARIANCE ESTIMATES. E depois clicar no botão SUMMARY, na parte superior direita da janela acima.

Você obterá um resultado de *output* com formato parecido aos anteriores, só que com a adição de três novas colunas:

Mean Group 1	Mean Group 2	t-value	df	p	t separ. var.est.	df	p 2-sided	Valid N Group 1	Valid N Group 2	Std.Dev. Group 1	Std.Dev. Group 2	F-ratio Variances	p Variances

Nos foquemos nestas três novas colunas.

t separ. var.est.	df	p 2-sided

Elas são a estatística t, os graus de liberdade, e o valor de p, para este teste t feito a partir do procedimento de estimativas separadas de variâncias, que é adequado para quando temos variâncias distintas, ou n amostrais de tamanhos muito diferentes entre os dois grupos que estão sendo comparados.

Repare nas diferenças entre os graus de liberdade em relação ao teste t para amostras independentes convencional. Veja que há PERDA DE GRAUS DE LIBERDADE, OU SEJA: perda de peças de informação. Portanto, essa é uma abordagem menos poderosa que o teste t convencional, é por isso que tentamos de todas as formas obter as variâncias homogêneas por meio das transformações dos dados, se tivéssemos obtido, o teste feito mesmo com os dados logaritimizados ou com a raiz quadrada, teria mais graus de liberdade que o teste feito através desse procedimento. Mas ele é perfeitamente válido, e mais poderoso do que se simplesmente tivéssemos saltado para uma alternativa não paramétrica.

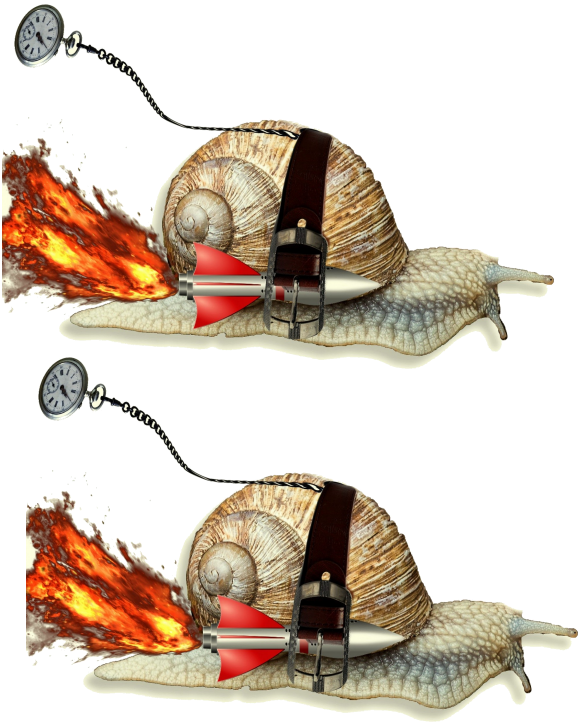
Em Resumo

Quando os pressupostos de normalidade ou homogeneidade de variâncias não são atendidos, tentamos as transformações. Se estas não funcionam, a escolha natural são as alternativas não paramétricas, no entanto, no caso do teste t, existe um teste t especial, utilizado para os casos em que as variâncias são distintas ou os *n* amostrais são muito diferentes entre os dois grupos que estão sendo comparados. Ele é preferível a uma alternativa não paramétrica porque tem mais poder (capacidade de capturar uma diferença caso ela exista), mas tem menos graus de liberdade que um teste t para variâncias heterogêneas convencional, assim, embora mais poderoso que um teste não paramétrico, ele é menos poderoso que um teste t que não utiliza o método de estimativas separadas para variâncias.

CAPÍTULO 8

TESTE T PARA AMOSTRAS PAREADAS

Como executar e interpretar o teste t para amostras pareadas



Dados pareados são aqueles nos quais são realizadas duas medidas numa mesma unidade amostral. Por exemplo, aferição de pressão sanguínea ou concentrações sanguíneas em pacientes antes e depois de uma intervenção, ou mensuração de parâmetros físico químicos na chuva e na seca em um mesmo ambiente. Amostras pareadas são também chamadas de amostras dependentes. Novamente temos o cenário de duas médias a serem comparadas, mas não trata-se aqui de dois grupos distintos, e sim, do mesmo grupo, com mensurações realizadas em momentos distintos. Para a comparação destas médias utilizamos o Teste t para amostras pareadas.

O teste t para amostras pareadas NÃO POSSUI O PRESSUPOSTO DE HOMOGENEIDADE DE VARIÂNCIAS, e o pressuposto de normalidade é um pouco distinto, ele não exige exatamente que a variável seja normalmente distribuída dentro do grupo, mas isto sim, que as distribuições das diferenças entre os valores pareados sejam aproximadamente normais. Fala-se de fato em aproximadamente normais devido a robustez do teste t pareado a violação deste pressuposto. Assim como em qualquer teste estatístico, a presença de valores discrepantes, os *outliers*, também afeta drasticamente as estimativas.

Procedamos então ao teste t pareado. Se o experimento foi planejado corretamente a única preocupação de pressupostos que temos na prática é a seguinte: as diferenças entre os valores das amostras pareadas seguem uma distribuição normal?



Para trabalhar com o teste t pareado nós tomaremos o seguinte exemplo. Liquens são comumente utilizados como biondicadores de poluição ambiental. Um pesquisador coletou táxons de liquens, antes e depois de um empreendimento industrial em 7 áreas de um determinado estado brasileiro. A hipótese dele é que o número de táxons de liquens é menor naquele estado após o empreendimento em comparação com antes de o empreendimento ser implantado. Os dados dele são os seguintes:

Antes do Empreendimento	Após o Empreendimento
12	11
7	6
9	5
19	14
13	6
14	9
11	2

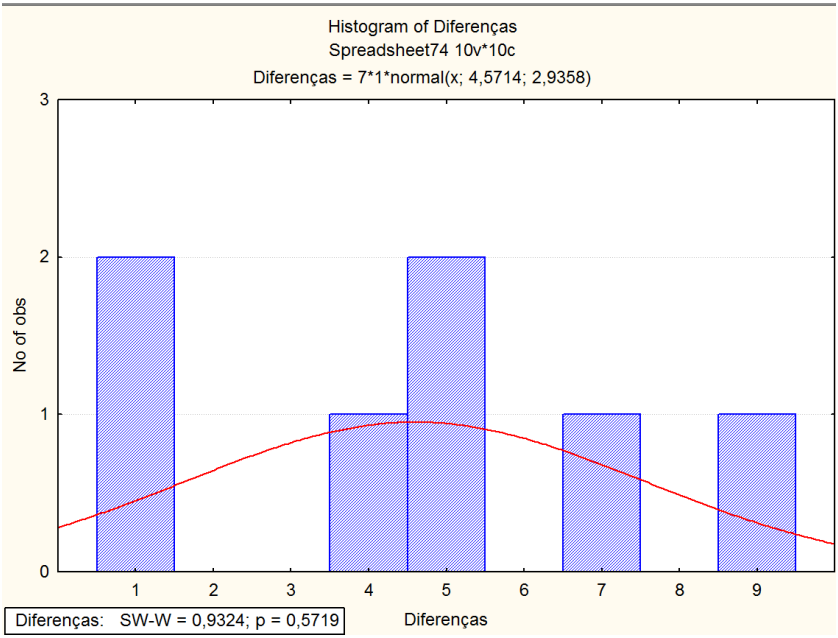
Os números representam a quantidade de táxons de liquens, e cada linha da tabela é uma área. Claramente temos então duas médias a serem comparadas, então a ferramenta a ser utilizada é um teste t. No entanto, temos amostras pareadas, a rigor não são dois grupos de áreas distintos, apenas o mesmo grupo de áreas em dois momentos diferentes no tempo.

Vamos criar mais uma coluna nesta tabela, que será a diferença entre o número de táxons antes do empreendimento industrial e após a instalação do empreendimento industrial, isto é, o primeiro valor subtraído do segundo:

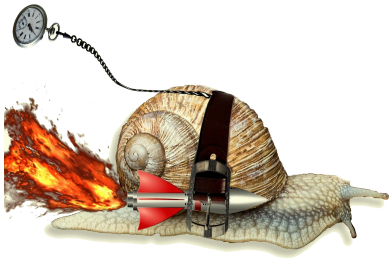
Antes do Empreendimento	Após o Empreendimento	Diferenças
12	11	1
7	6	1
9	5	4
19	14	5
13	6	7
14	9	5
11	2	9

Vamos então inserir estes dados no Statistica, e primeiro verificaremos se a terceira coluna de nossa tabela, a diferença entre o número de táxons antes do empreendimento e após o empreendimento, segue uma distribuição normal, pressuposto básico do teste t para amostras pareadas.

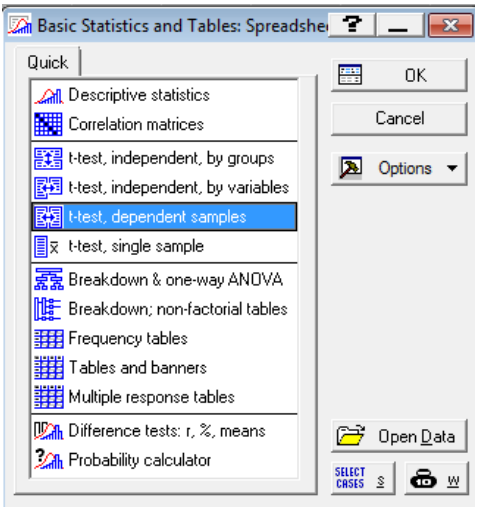
Para isto vamos construir um Histograma para a variável Diferenças. Clique em GRAPHS/ HISTOGRAMS/ em seguida clique em ADVANCED. Clique em *VARIABLES*/ Selecione a variável Diferenças, em seguida clique em OK. Marque a opção Shapiro/Wilk Test e clique em OK. Deverá ver um gráfico como o abaixo:



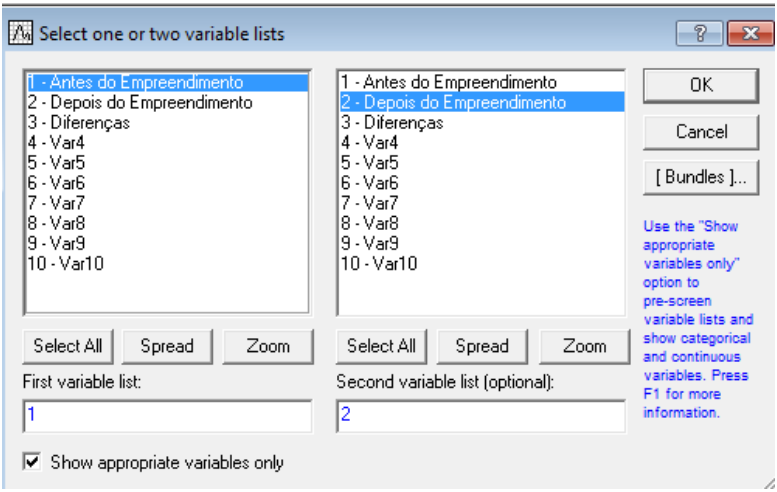
Conforme já aprendemos, pela forma da curva e pelo valor de p no teste de Shapiro Wilk, podemos concluir que os dados da variável diferenças seguem sim uma distribuição normal. Logo, podemos prosseguir para a execução do teste t pareado.



Procedamos então para a execução do teste t pareado. Clique em STATISTICS/BASIC STATISTIC TABLES /T TEST, DEPENDENT SAMPLES:



Clique em *VARIABLES*. Do lado esquerdo selecione Antes do Empreendimento, e do lado direito selecione Depois do Empreendimento:



Agora basta clica em OK, e depois no botão SUMMARY T TEST, e obterá o seguinte resultado:

Variable	T-test for Dependent Samples (Spreadsheet74) Marked differences are significant at p < ,05000							
	Mean	Std.Dv.	N	Diff.	Std.Dv. Diff.	t	df	p
Antes do Empreendimento	12,14286	3,848314						
Depois do Empreendimento	7,57143	4,035556	7	4,571429	2,935821	4,119754	6	0,006218

Como em qualquer teste, a primeira coisa que vamos olhar é o valor de p. Ele foi menor que 0,05, logo a diferença no número de táxons antes e depois do empreendimento não é mero artefato do acaso.

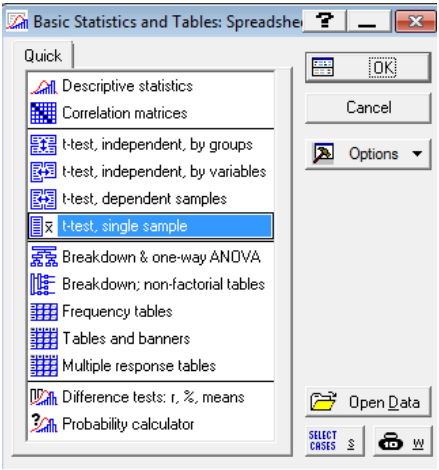
Como a média do número de táxons é menor Depois do empreendimento (7,571) em comparação com Antes do empreendimento (12,142), concluímos assim que o número de táxons de fato é menor nas áreas estudadas após o empreendimento em comparação com antes, o que sugere que o mesmo provocou um impacto ambiental considerável sobre o local. (t=4,12, GL=6,p=0,006).

Se o pesquisador quiser pode optar por escrever p<0,01 ao invés de p=0,006. E assim temos concluído o teste t para amostras pareadas.

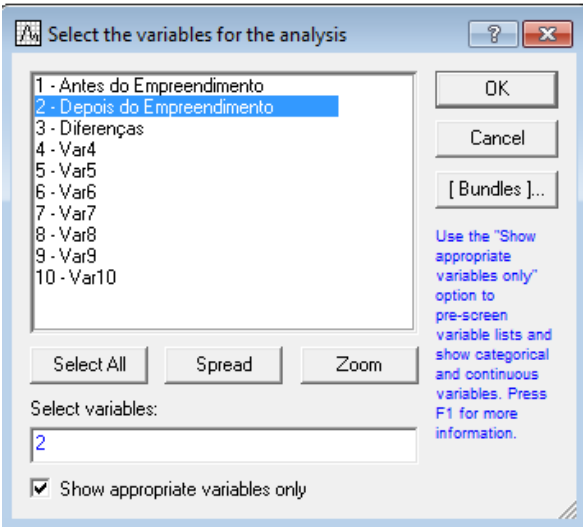
Teste t para uma única amostra

O outro teste t que existe é muito simples, ele serve pra comparar a média de um grupo com uma média fixa. Por exemplo, suponhamos que no caso anterior o pesquisador por infelicidade perdeu seus dados de coletas em campo antes do empreendimento, já que eram dados muito antigos. Ele tem apenas o valor da média do número de táxons para a época anterior ao empreendimento. Então, se o empreendimento não causou alteração, espera-se que a média de riqueza no lugar seja hoje do mesmo modo que era no passado (claro que há muitos fatores teóricos em ecologia para serem considerados aqui, mas simplifiquemos a questão a fim de exemplo). Então a média antes era de 12,14 para a riqueza de espécies. O que ela quer é simplesmente comparar a média depois do empreendimento com a média antes! Então o que temos são os dados após a implantação do empreendimento e uma única média de referência para fazer a comparação.

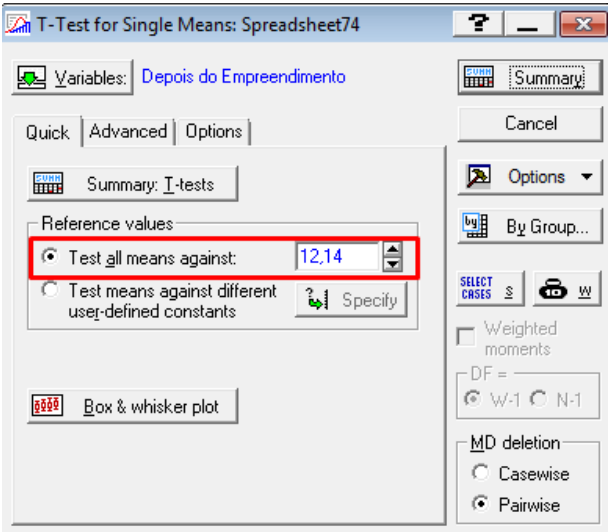
O pressuposto do teste t para uma única amostra é que os dados da amostra seguem aproximadamente uma distribuição normal, o que já verificamos nos passos anteriores, no mais a interpretação dele é idêntica a dos testes anteriores. então para executá-lo basta utilizar a seguinte sequência : clique em STATISTICS /BASIC STATISTICS TABLES/ T-TESTE SINGLE SAMPLE, conforme mostra a figura seguinte:



Em seguida clique em *VARIABLE*S e selecione Depois do Empreendimento, após selecioná-la clique em OK:



Agora digite a média de referência, no caso 12,14, no campo TEST ALL MEANS AGAINST, assinalado na figura abaixo:



Agora basta clicar em SUMMARY T TEST, e seguirá o seguinte resultado:

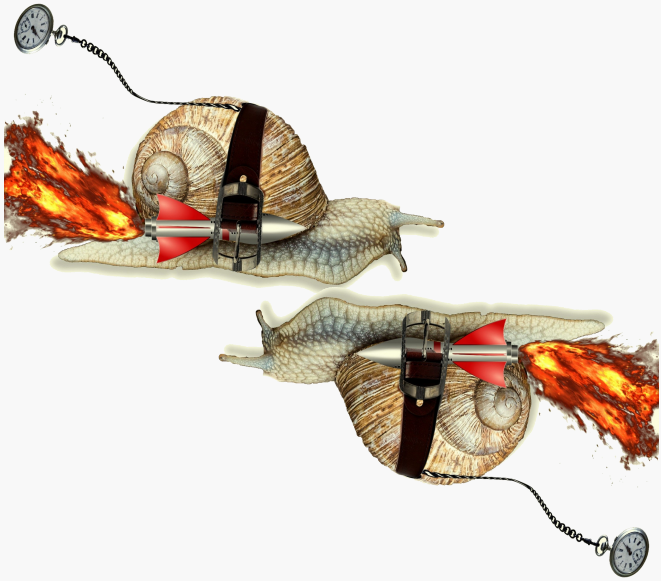
	Test of means against reference constant (value) (Spreadsheet74)							
Variable	**Mean**	Std.Dv.	N	Std.Err.	Reference Constant	t-value	df	p
Depois do Empreendimento	7,571429	4,035556	7	1,525297	12,14000	-2,99520	6	0,024157

Como sempre, olhamos sempre para o p estatístico primeiro, ele é significativo, como a média depois, 7,57, é menor que a média antes, concluímos que as diferenças entre as médias não são mero artefato do acaso. Assim, mesmo tendo perdido o conjunto de dados do passado, o pesquisador ainda pôde confirmar sua suspeita de que a riqueza de espécies de liquens de fato foi reduzida após a implantação do empreendimento.

CAPÍTULO 9

EQUIVALENTES NÃO PARAMÉTRICOS

Ranks, Teste U de Mann Whitney e Teste de Wilcoxon



Os testes não paramétricos são a opção que utilizamos quando os pressupostos básicos dos testes paramétricos não funcionam. Eles possuem como desvantagem o fato de serem menos poderosos. Alguns autores como Nicholas Gotelli, em *A Primer of Ecological Statistics*, argumentam que essa diferença de poder em comparação com os testes paramétricos é bem considerável, já autores de textos clássicos em bioestatística, como Jerrold H. Zar, *Bioestatistical Analysis,* argumentam que essa diferença de poder existe, mas não é assim tão acentuada, podendo um incremento no *n* amostral compensá-la. O raciocínio de Zar é que se aumentamos o número de peças de informação, incrementamos o poder do teste não paramétrico a ponto de deixá-lo praticamente equivalente ao não paramétrico com um *n* amostral menor.

A vantagem é a ausência da necessidade de que os pressupostos de normalidade dos dados ou de homogeneidade das variâncias sejam seguidos. Porém, uma desvantagem clara dos testes não paramétricos é que eles trabalham com os dados ranqueados. Ranquear dados é ordená-los, do menor para o maior. Assim, por exemplo, uma sequência de dados como 76, 128, 214 e 654, quando ranqueados se transformam simplesmente em 1,2,3,4 e 5, sendo 5 o maior dos valores. Perde-se claramente informação, detalhes de sutilezas quantitativas que podem haver nos dados, é como se as peças de informação originais fossem trituradas, e a informação se perde.

Então, ao invés de lidar diretamente com a comparação das médias, estes testes lidam com a soma dos Ranks. Ao invés de ter média para o grupo 1 e média para o grupo 2, o que você tem é soma de ranks para o grupo 1, soma de ranks para o grupo 2.

Veremos neste capítulo a execução de dois testes não paramétricos, um equivalente ao teste t para amostras independentes, o teste U de Mann Whitney, e o outro equivalente ao teste t para amostras pareadas, o teste de Wilcoxon. A execução deles é bem simples, e sua interpretação embora não seja tão informativa quanto a dos testes paramétricos, também é de fácil compreensão.

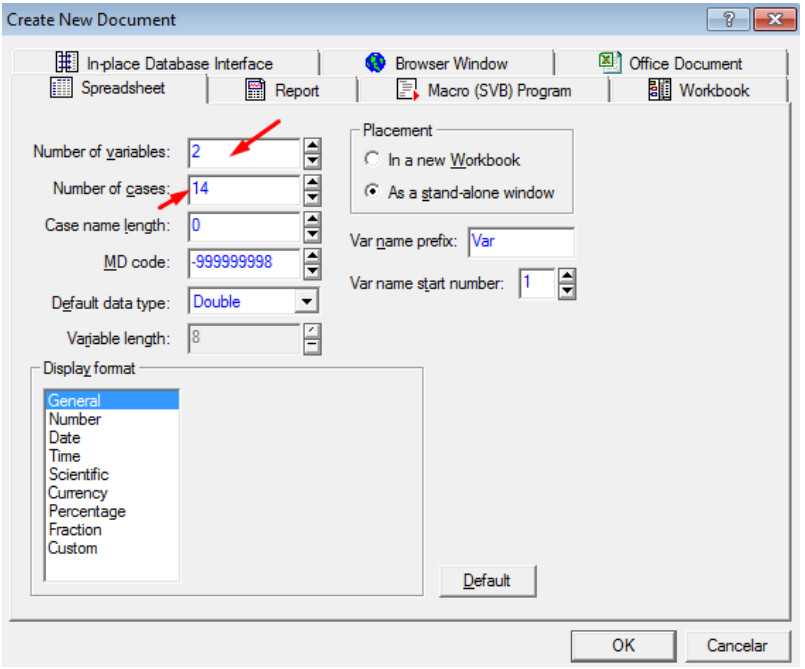
Comecemos com o teste U de Mann Whitney. Vamos utilizar o mesmo conjunto de dados anterior. Novamente temos dois meios de cultura a serem comparados, o meio enriquecido e o meio Pobre em nutrientes. No entanto, vamos tabelar esses dados de uma maneira distinta, criaremos uma variável chamada: TIPO DE TRATAMENTO, E OUTRA VARIÁVEL CHAMADA BIOMASSA. E organizaremos os dados segundo a tabela abaixo (isso é feito para facilitar a entrada deles no software).

TRATAMENTO	BIOMASSA
Rico em Nutrientes	8
Rico em Nutrientes	9
Rico em Nutrientes	9
Rico em Nutrientes	6
Rico em Nutrientes	7
Rico em Nutrientes	8
Rico em Nutrientes	9
Pobre em Nutrientes	12
Pobre em Nutrientes	3
Pobre em Nutrientes	6
Pobre em Nutrientes	7
Pobre em Nutrientes	6
Pobre em Nutrientes	7
Pobre em Nutrientes	4

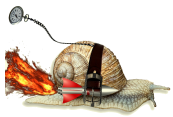
A variável tratamento é denominada de *Grouping Variable* ou Variável de agrupamento. Cada linha é uma placa na qual foi feito o experimento do cultivo do fungo. Vamos entrar com os dados acima no Statistica. Até agora havíamos trabalhado com planilhas com apenas 10 linhas. Para criar uma planilha com mais linhas você tem duas opções no Statistica, a primeira é criar um novo arquivo e nele especificar mais que 10 linhas, e a segunda é simplesmente adicionar mais linhas a uma planilha de 10 linhas já existente. Vejamos cada um destes passos.

Criando um arquivo com mais linhas de dados

Clique em FILE/NEW e em seguida especifique quantas linhas (NUMBER OF CASES) e quantas colunas (NUMBER OF VARIABLES) o novo arquivo deverá ter. Conforme abaixo estaremos criando um arquivo com 14 linhas e 2 colunas.

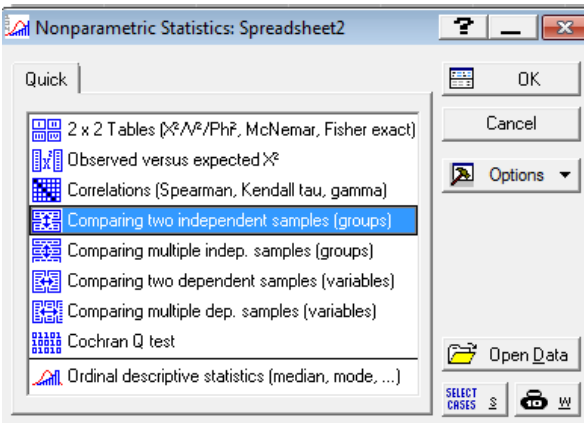


Uma vez assim feito você pode renomear as variáveis e preencher a planilha com os dados anteriores. Se já está com uma planilha aberta e não gostaria de criar um novo arquivo você pode simplesmente adicionar novas linhas (CASES) ao seu arquivo. Basta pra isso clicar em INSERT/ADD CASES e escolher quantas novas linhas quer adicionar. Agora podemos inserir os dados e executar a análise.

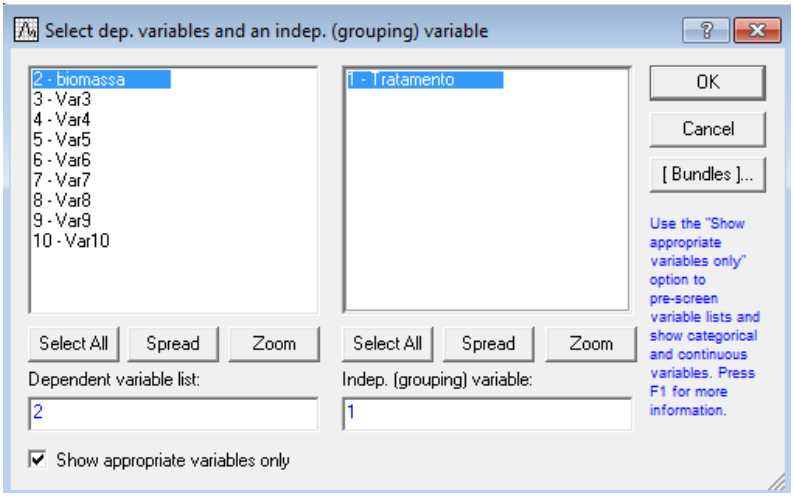


Nossa hipótese é de que o meio enriquecido promove maior biomassa, então, vamos testar se a diferença entre as biomassas pode ser atribuída ao acaso ou não a partir do teste U de Mann Whitney. Importante notar que AQUI NÃO ESTAREMOS COMPARANDO MÉDIAS, e sim utilizando uma técnica não paramétrica equivalente que na verdade substitui os dados originais por dados ranqueados, e utiliza a soma dos ranks como um equivalente às médias durante a análise. O grupo que tiver maior soma de Ranks é o que terá maior biomassa (caso o teste dê significativo).

Executemos então a análise. Para tal, basta entrar com os dados acima no Software Statistica em seguida clicar em STATISTICS/NON PARAMETRICS/COMPARING TWO INDEPENDENT SAMPLES(*GROUP*S), conforme figura abaixo.

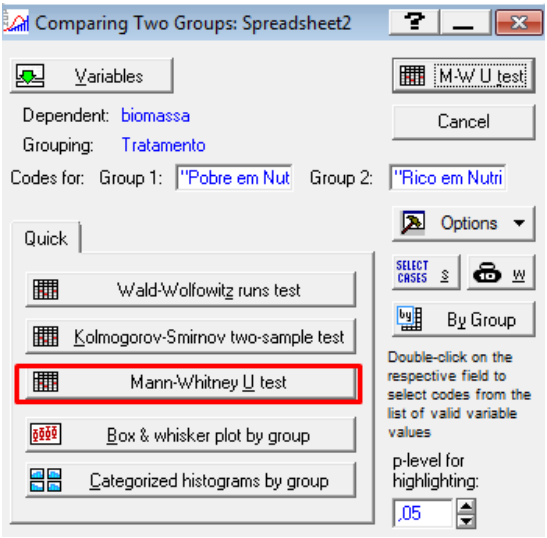


Em seguida clique em VARIABLES. Do lado esquerdo marque a variável BIOMASSA, e do lado direito (*Indep. Grouping Variable*) marque a variável TRATAMENTO, conforme abaixo.



A *Grouping Variable* ou variável de agrupamento é chamada de variável independente ou variável preditora, porque determina o valor da variável biomassa. Já a Biomassa é chamada de variável dependente, pois o valor dela, depende do tipo de tratamento. Há quem critique essas nomenclaturas, mas elas ainda são bem usuais.

Agora basta clicar em OK, e depois no botão MANN WHITNEY U TEST conforme assinalado na figura abaixo.



O resultado será o seguinte:

Mann-Whitney U Test (Spreadsheet2)
By variable Tratamento
Marked tests are significant at p <,05000

variable	Rank Sum Pobre em Nutrientes	Rank Sum Rico em Nutrientes	U	Z	p-level	Z adjusted	p-level	Valid N Pobre em Nutrientes	Valid N Rico em Nutrientes	2*1sided exact p
biomassa	39,00000	66,00000	11,00000	-1,72497	0,084534	-1,75015	0,080093	7	7	0,097319

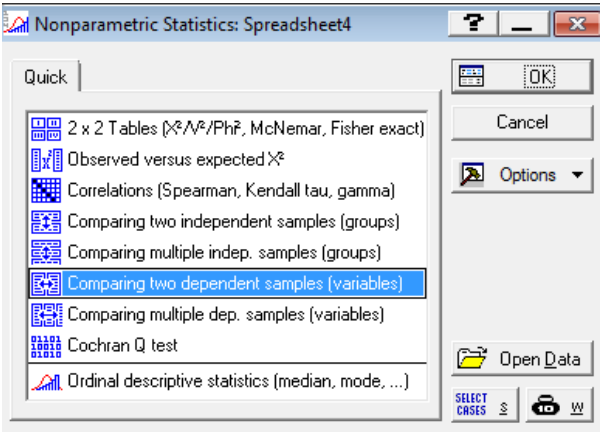
Vamos buscar primeiramente o valor de p, ele está na quinta coluna, foi de 0,08. Ou seja, de acordo com o teste U de Mann Whitney não há diferenças entre os as biomassas para os dois tipos de tratamento. A Terceira Coluna tem a estatística U da análise, as duas primeiras implicam nas respectivas somas de Rank para os dois meios utilizados. As demais colunas não são importante no momento para interpretação. Então a conclusão é: *as biomassas não diferem entre os meios, já que o p é não significativo, logo, não podemos descartar a hipótese nula*.

Por fim, vamos executar agora o teste de Wilcoxon, que seria o equivalente não paramétrico a um teste t para amostras pareadas. Vamos utilizar o mesmo exemplo da sessão anterior, os dados de número de táxons de liquens, antes e após a implantação do empreendimento industrial. Entremos então no Statistica com os dados abaixo.

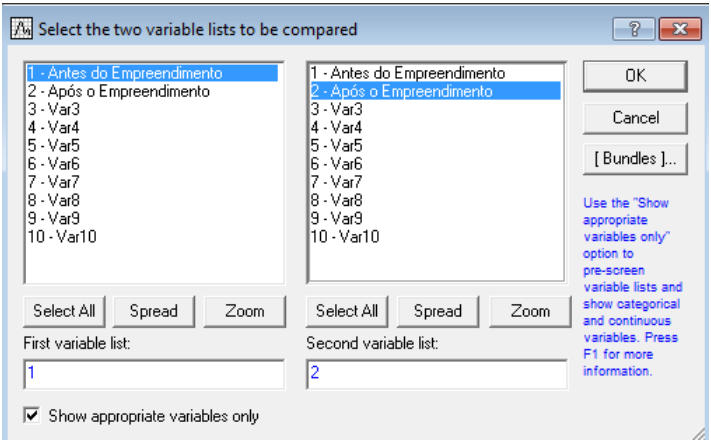
Antes do Empreen-dimento	Após o Empreen-dimento
12	11
7	6
9	5
19	14
13	6
14	9
11	2

A hipótese de pesquisa é de que o número de táxons é menor após o empreendimento, já que este teoricamente causaria impacto diminuindo quantidade de táxons de liquens da região.

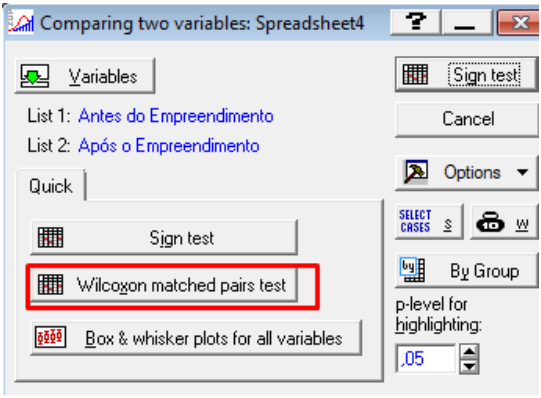
Vamos utilizar então o teste de Wilcoxon. Clique em STATISTICS/NON PARAMETRICS e em seguida escolha COMPARING TWO DEPENDENT SAMPLES (*VARIABLES*), conforme figura abaixo.



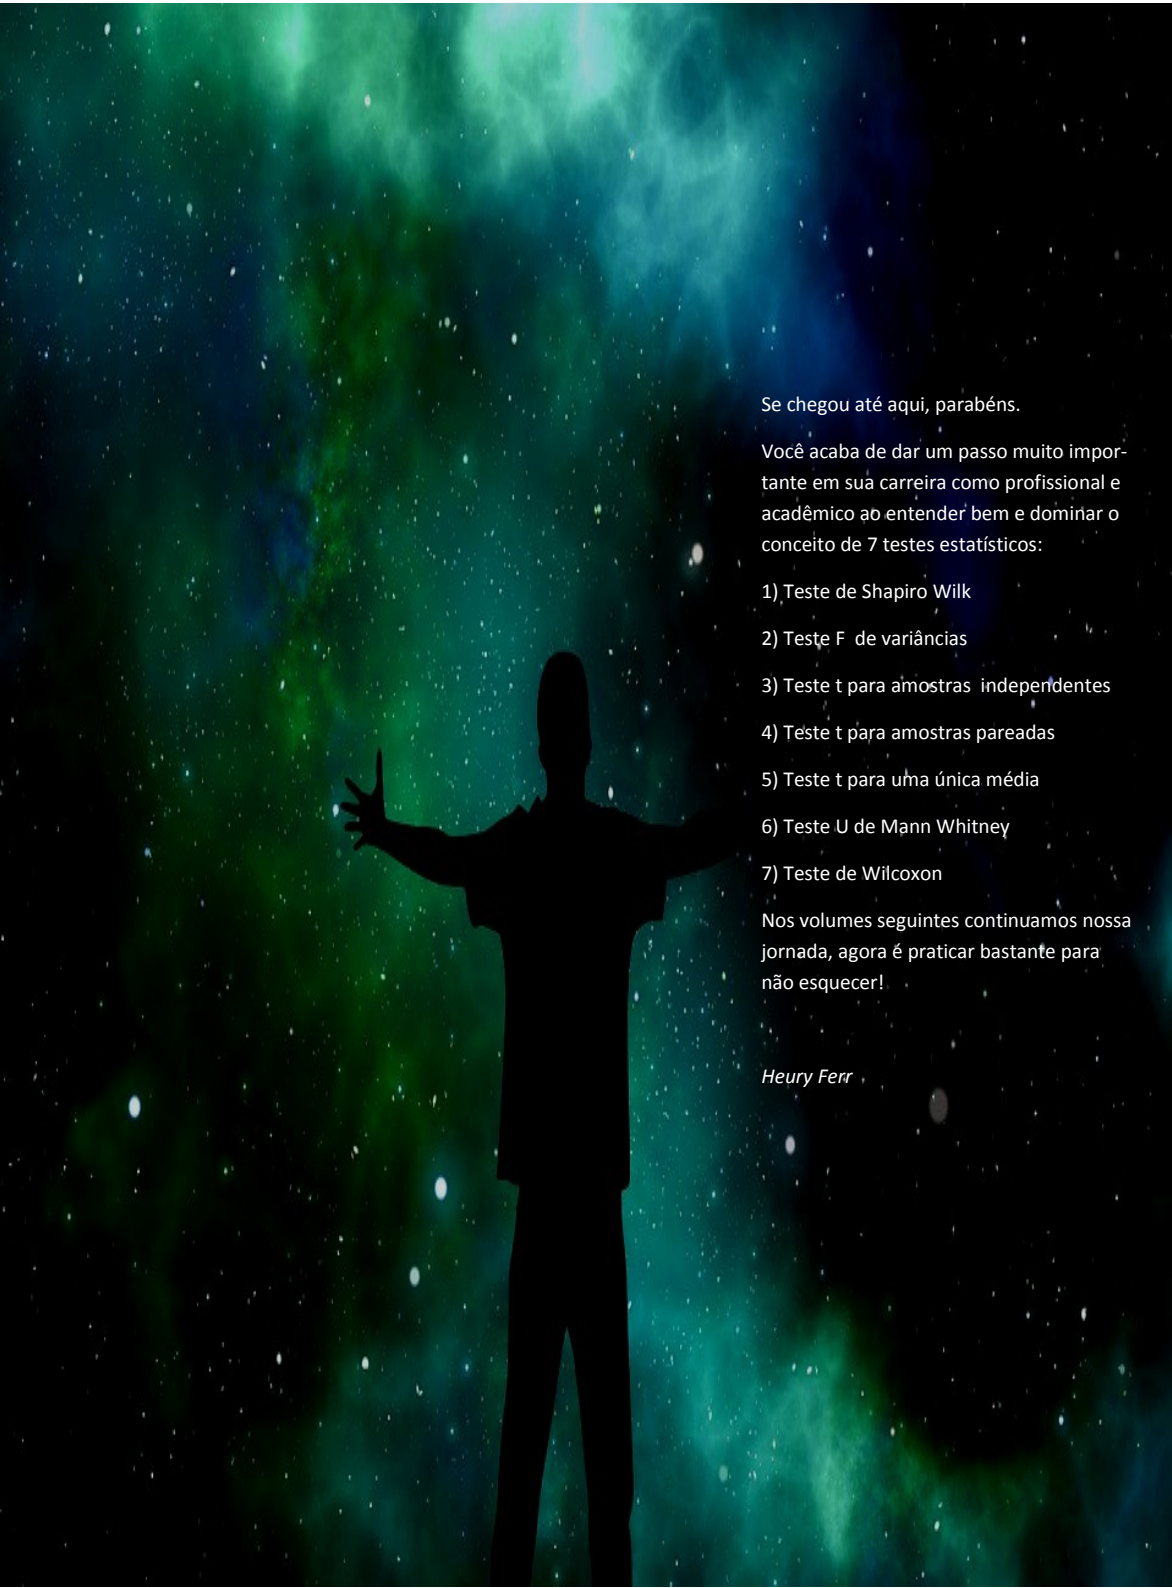
Agora clique em *VARIABLES* e escolha do lado esquerdo Antes do Empreendimento, e do lado direito Após o Empreendimento, conforme abaixo.



Clique em OK, e em seguida no botão WILCOXON MATCHED PAIR TEST conforme assinalado na figura abaixo:



Está executado o teste de WILCOXON, a estatística do teste é o Z, e o valor de p foi significativo, p=0,0179, rejeita-se a hipótese nula de que as riquezas eram iguais antes e após a implantação do empreendimento.



Se chegou até aqui, parabéns.

Você acaba de dar um passo muito importante em sua carreira como profissional e acadêmico ao entender bem e dominar o conceito de 7 testes estatísticos:

1) Teste de Shapiro Wilk

2) Teste F de variâncias

3) Teste t para amostras independentes

4) Teste t para amostras pareadas

5) Teste t para uma única média

6) Teste U de Mann Whitney

7) Teste de Wilcoxon

Nos volumes seguintes continuamos nossa jornada, agora é praticar bastante para não esquecer!

Heury Ferr



R E F E R Ê N C I A S

Baker, M. 2016. *Statisticians issue warning on P values Statement aims to halt missteps in the quest for certainty*. Nature. March, 2016, Vol 531.

Gotelli, N.J. Ellison, A.M. 2004. *A primer of Ecological Statistics.* SINAUER.

Nuzzo, R. 2014. *Statistical Erros: P values, the 'gold standard' of statistical validity, are not as reliable as many scientists assume*. Nature. Feb, 2014, Vol 506.

Raju, T.N. (2005). *William Sealy Gosset and William A. Silverman: two "students" of science*. Pediatrics . Vol 116 (3): 732–5.

Student. 1908. *The Probable Error of a Mean*. Biometrika, Vol 6(1), 1-25.

Zar, J. H. 2010. *Bioestatistical Analysis*. Fifith Edition, Pearson Prentice Hall.



ISBN 978-152022209-7